



深度學習基本原理 (Fundamentals of Deep Learning)

第二部分：如何訓練類神經網路 (How a Neural Network Trains)

課程大綱

- 第 1 部分：深度學習簡介
- 第 2 部分：神經網路如何訓練
- 第 3 部分：卷積神經網路
(Convolutional Neural Networks)
- 第 4 部分：資料增強與部署
- 第 5 部分：預訓練模型
- 第 6 部分：進階架構

課程練習回顧

剛才發生了什麼事？

載入並視覺化我們的資料

編輯資料(正確的資料格式, 正規化(Normalization), 轉換成類別)

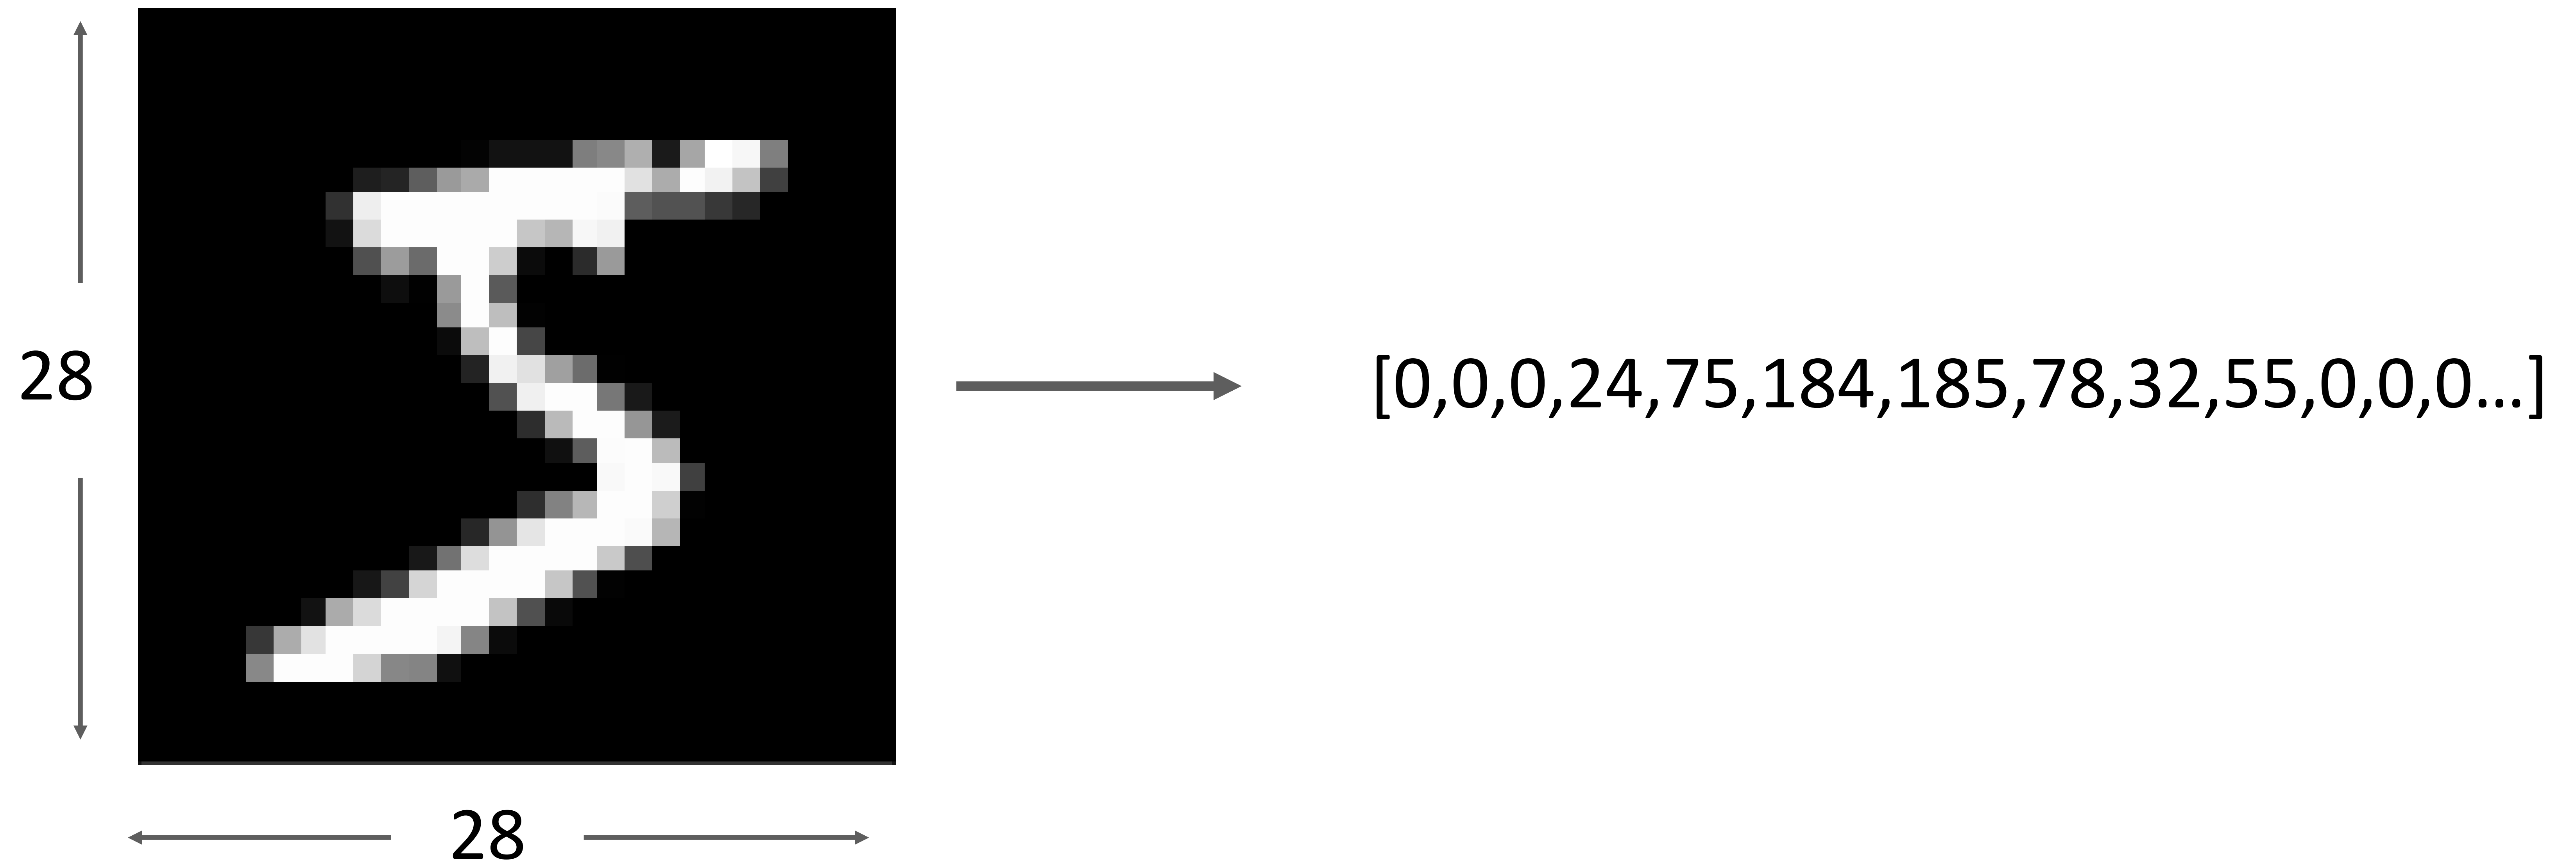
建立模型

編譯(Compiled)模型

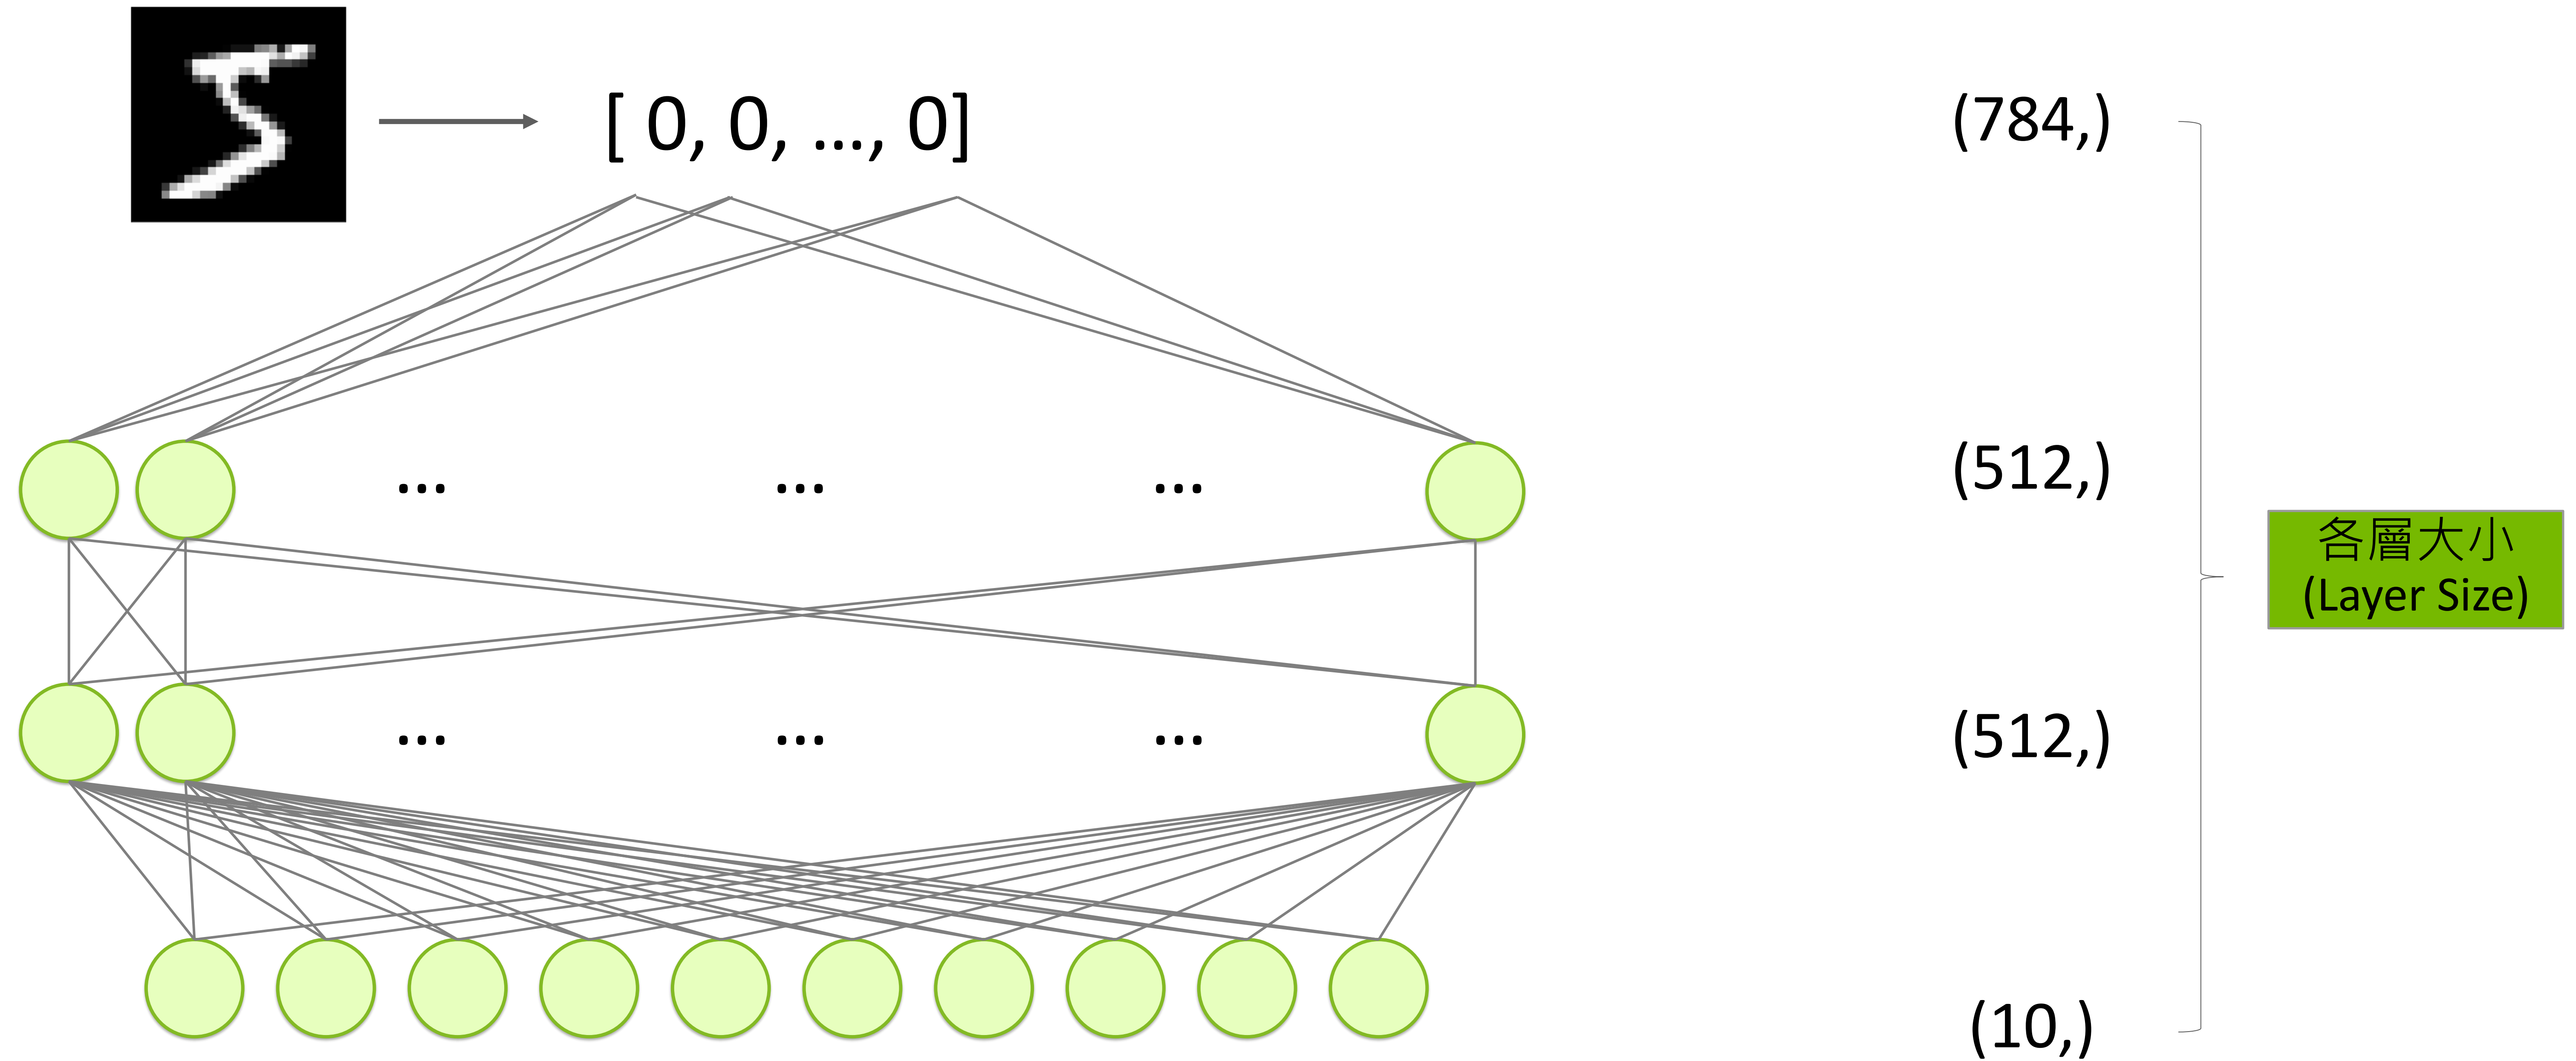
用資料訓練了模型

資料準備(Data Preparation)

以陣列格式輸入 (Input as an Array)



未訓練的模型(An Untrained Model)





更簡化的模型(A Simpler Model)

更簡化的模型(A Simpler Model)

$$y = mx + b$$

x	y
1	3
2	5



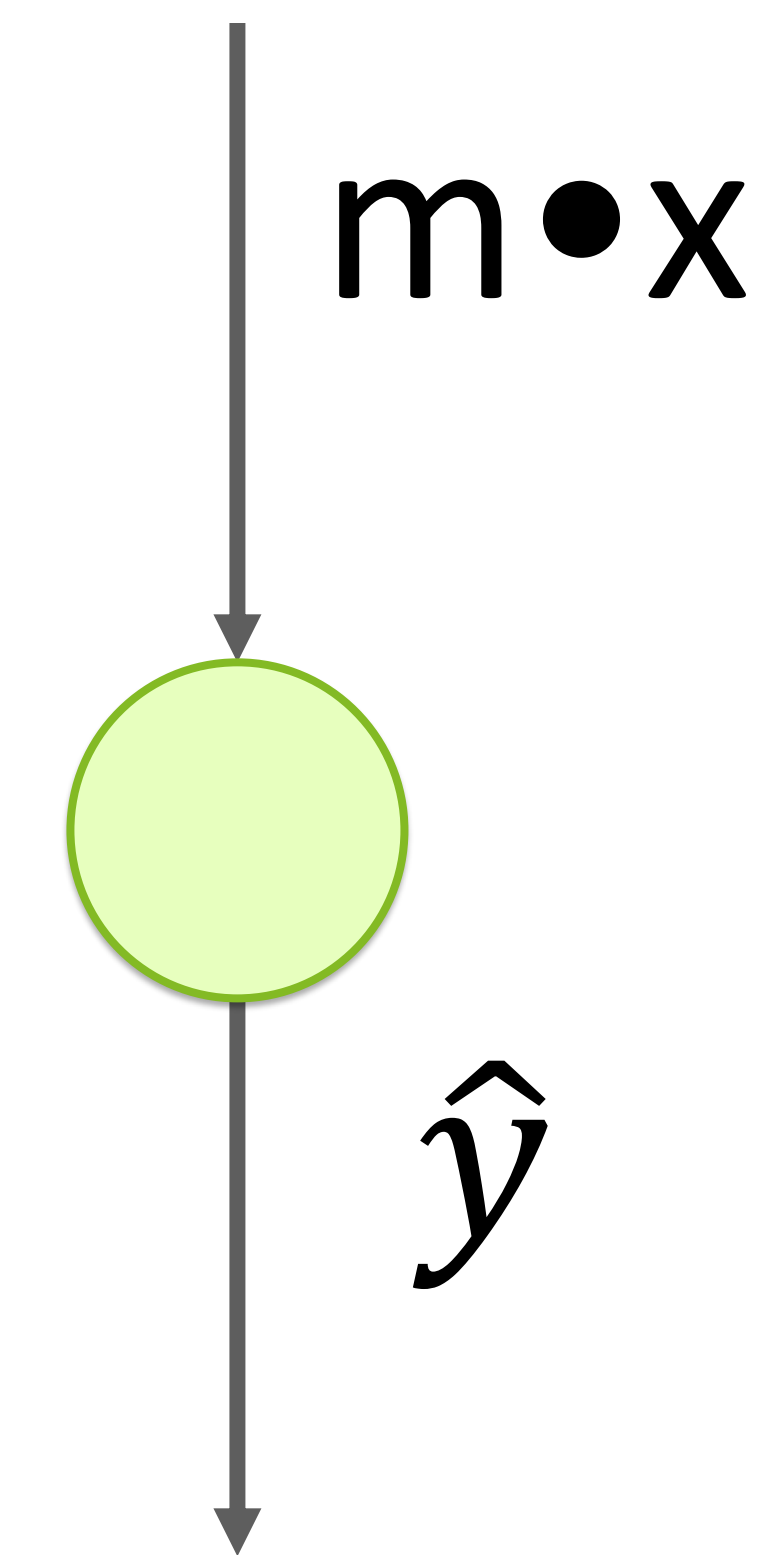

$$m = ?$$

$$b = ?$$

更簡化的模型(A Simpler Model)

$$y = mx + b$$

x	y
1	3
2	5





$$m = ?$$

$$b = ?$$

更簡化的模型(A Simpler Model)

$$y = mx + b$$

x	y	\hat{y}
1	3	4
2	5	3



Start Random隨機開始(Start Random)

$$m = -1$$
$$b = 5$$


更簡化的模型(A Simpler Model)

$$y = mx + b$$

x	y	\hat{y}	err^2
1	3	4	1
2	5	3	4

$$MSE = 2.5$$

$$RMSE = 1.6$$



$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$


更簡化的模型(A Simpler Model)

$$y = mx + b$$

x	y	\hat{y}	err^2
1	3	4	1
2	5	3	4



MSE = 2.5

RMSE = 1.6




```
1 data = [(1, 3), (2, 5)]
2 m = -1
3 b = 5
4
5
6 def get_rmse(data, m, b):
7     """Calculates Mean Square Error"""
8     n = len(data)
9     squared_error = 0
10    for x, y in data:
11        # Find predicted y
12        y_hat = m*x+b
13        # Square difference between
14        # prediction and true value
15        squared_error += (
16            y - y_hat)**2
17        # Get average squared difference
18    mse = squared_error / n
19    # Square root for original units
20    return mse **.5
21
```


損失曲線(Loss Curve)




損失曲線(Loss Curve)



$$m = -1$$
$$b = 5$$




損失曲線(Loss Curve)




$$m = -1$$

$$b = 4$$




損失曲線(Loss Curve)




$$m = 0$$

$$b = 4$$



損失曲線(Loss Curve)


梯度 (Gradient)	損失函式(loss function)減少最多的方向
λ : 學習率 (learning rate)	移動的距離
Epoch	使用完整資料集更新模型
批次(Batch)	完整資料集的樣本
步驟(Step)	權重參數的更新



損失曲線(Loss Curve)

梯度 (Gradient)	損失函式(loss function)減少最多的方向
λ : 學習率 (learning rate)	移動的距離
Epoch	使用完整資料集更新模型
批次(Batch)	完整資料集的樣本
步驟(Step)	權重參數的更新

$$w := w - \eta \cdot \frac{\partial J}{\partial w}$$
$$b := b - \eta \cdot \frac{\partial J}{\partial b}$$



完整學習一次的流程（訓練流程）

1. 資料準備（Data Preparation）

將原始資料整理、標註，並劃分為訓練集與驗證集。

2. 初始化模型參數（Model Initialization）

設定初始權重、偏差等參數。

3. 設定訓練超參數（Hyperparameters）

例如：

- 學習率（learning rate）
- 批次大小（batch size）
- 訓練回合數（epoch）等。

4. 進入訓練迴圈：For 每個 Epoch（回合）

4.1 將訓練資料分成多個 Batch（小批次）

若批次大小為 32，而資料筆數為 320，則每個 epoch 有 10 個 batch。

4.2 對每個 Batch 執行以下 Step（步驟）：

- ► 前向傳播（Forward Pass）：
將資料輸入模型，計算預測結果。
- ► 損失計算（Loss Calculation）：
計算預測結果與真實值的差異（Loss Function）。
- ► 反向傳播（Backward Pass / Backpropagation）：
透過鏈式法則計算各參數對損失的偏導數（即梯度）。
- ► 參數更新（Step）：
使用梯度與學習率更新模型參數（通常使用 SGD、Adam 等優化器）。


5. 一整輪資料訓練完成，代表一個 Epoch 結束

6. 可選：使用驗證集進行評估（Validation）

觀察模型在未見過資料上的表現是否提升。

7. 重複步驟 4–6，直到達到指定的 Epoch 數量或提早停止（early stopping）


優化器(Optimizers)



- Adam
- Adagrad
- RMSprop
- SGD


從神經元到網路(From Neuron to Network)

建立網路(Building a Network)




- 擴展到更多輸入資料(Scales to more inputs)

建立網路(Building a Network)



- 擴展到更多輸入資料(Scales to more inputs)
- 可以鏈接神經元(Can chain neurons)

建立網路(Building a Network)



- 擴展到更多輸入(Scales to more inputs)
- 可以鏈接神經元(Can chain neurons)
- 如果所有回歸(regressions)都是線性的，那麼輸出也將是線性回歸

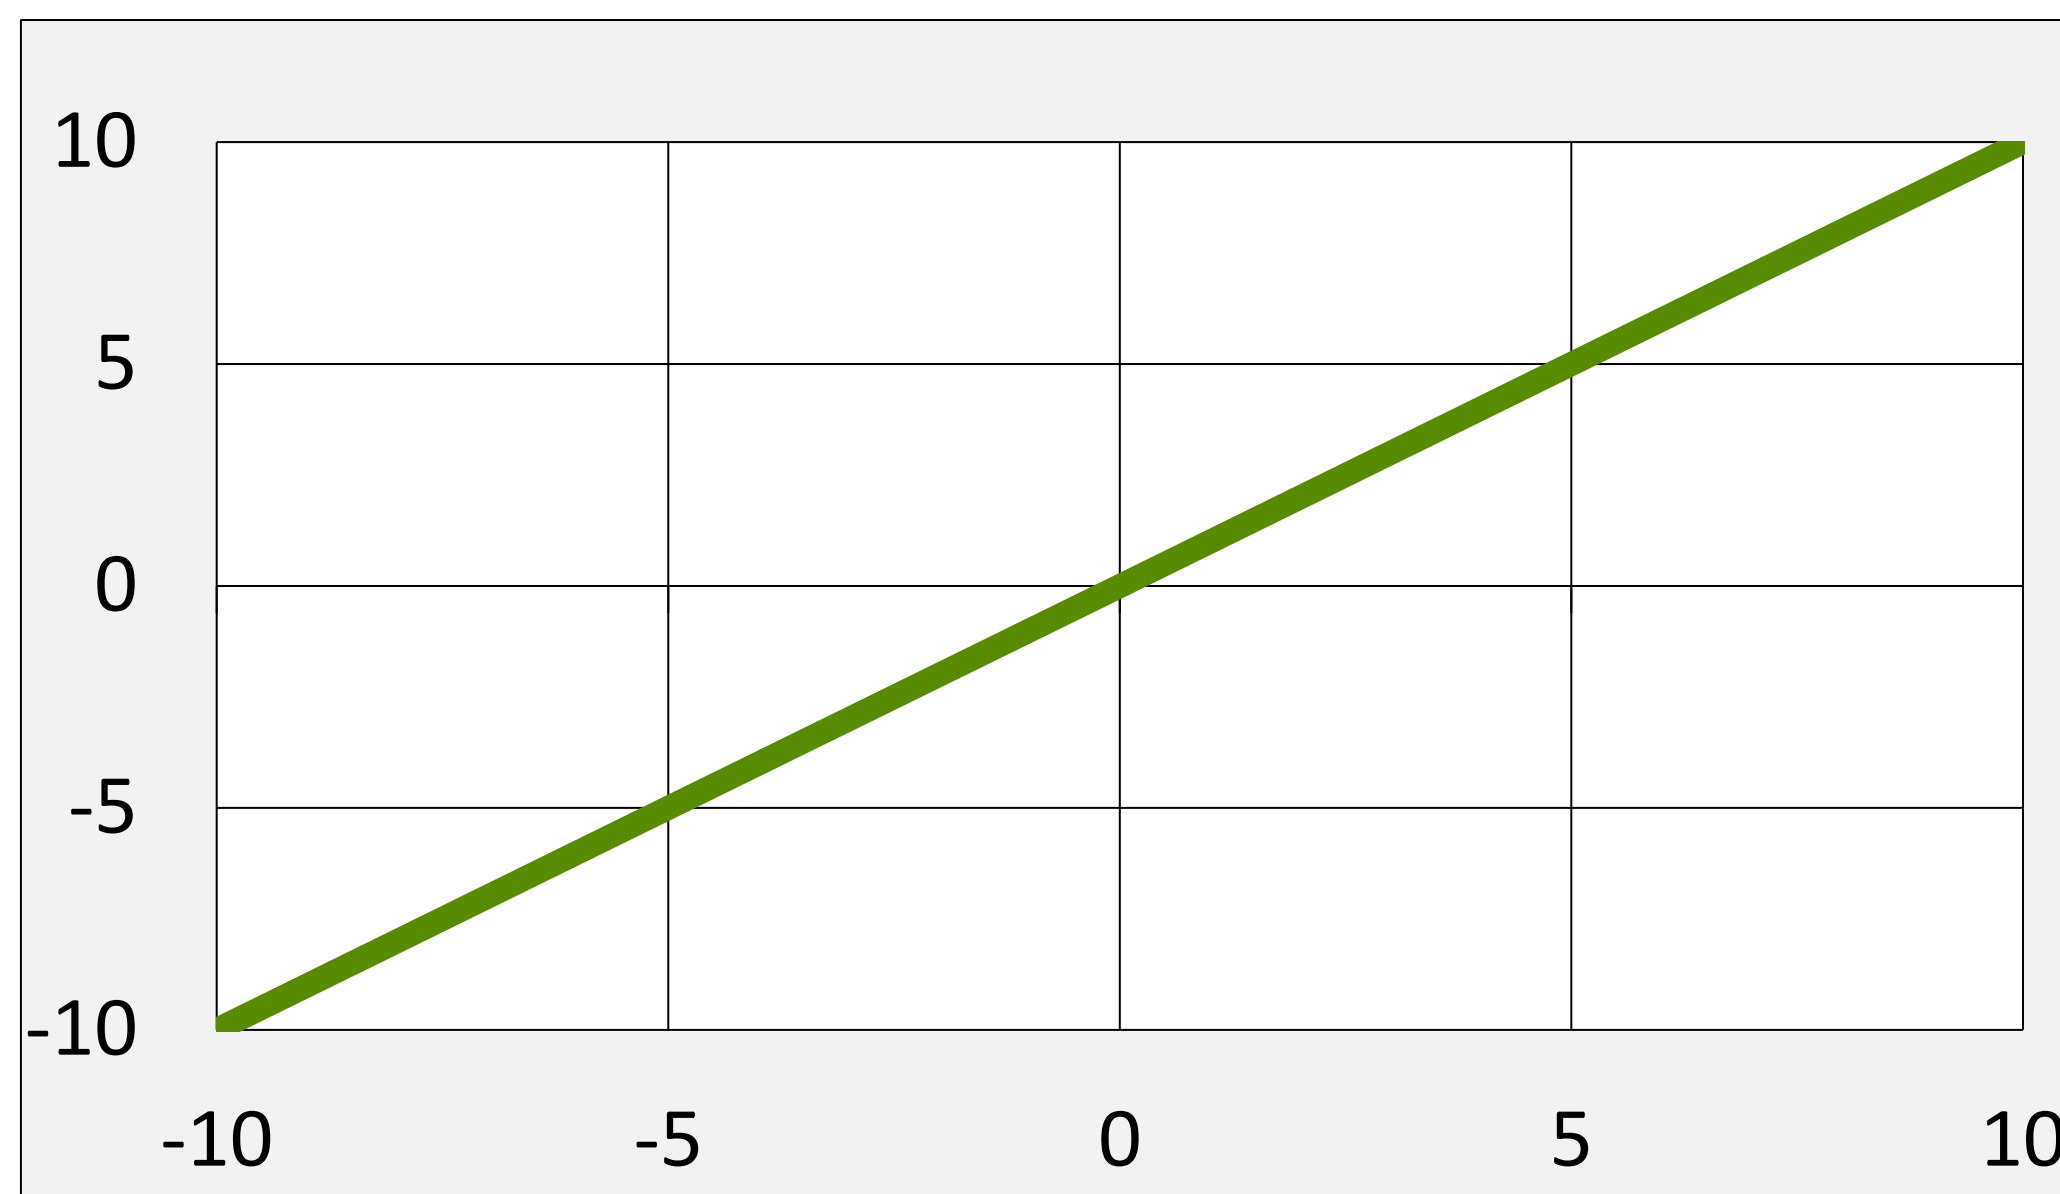
活化函数(Activation Functions)

活化函式(Activation Functions)

Linear線性(Linear)

$$\hat{y} = wx + b$$

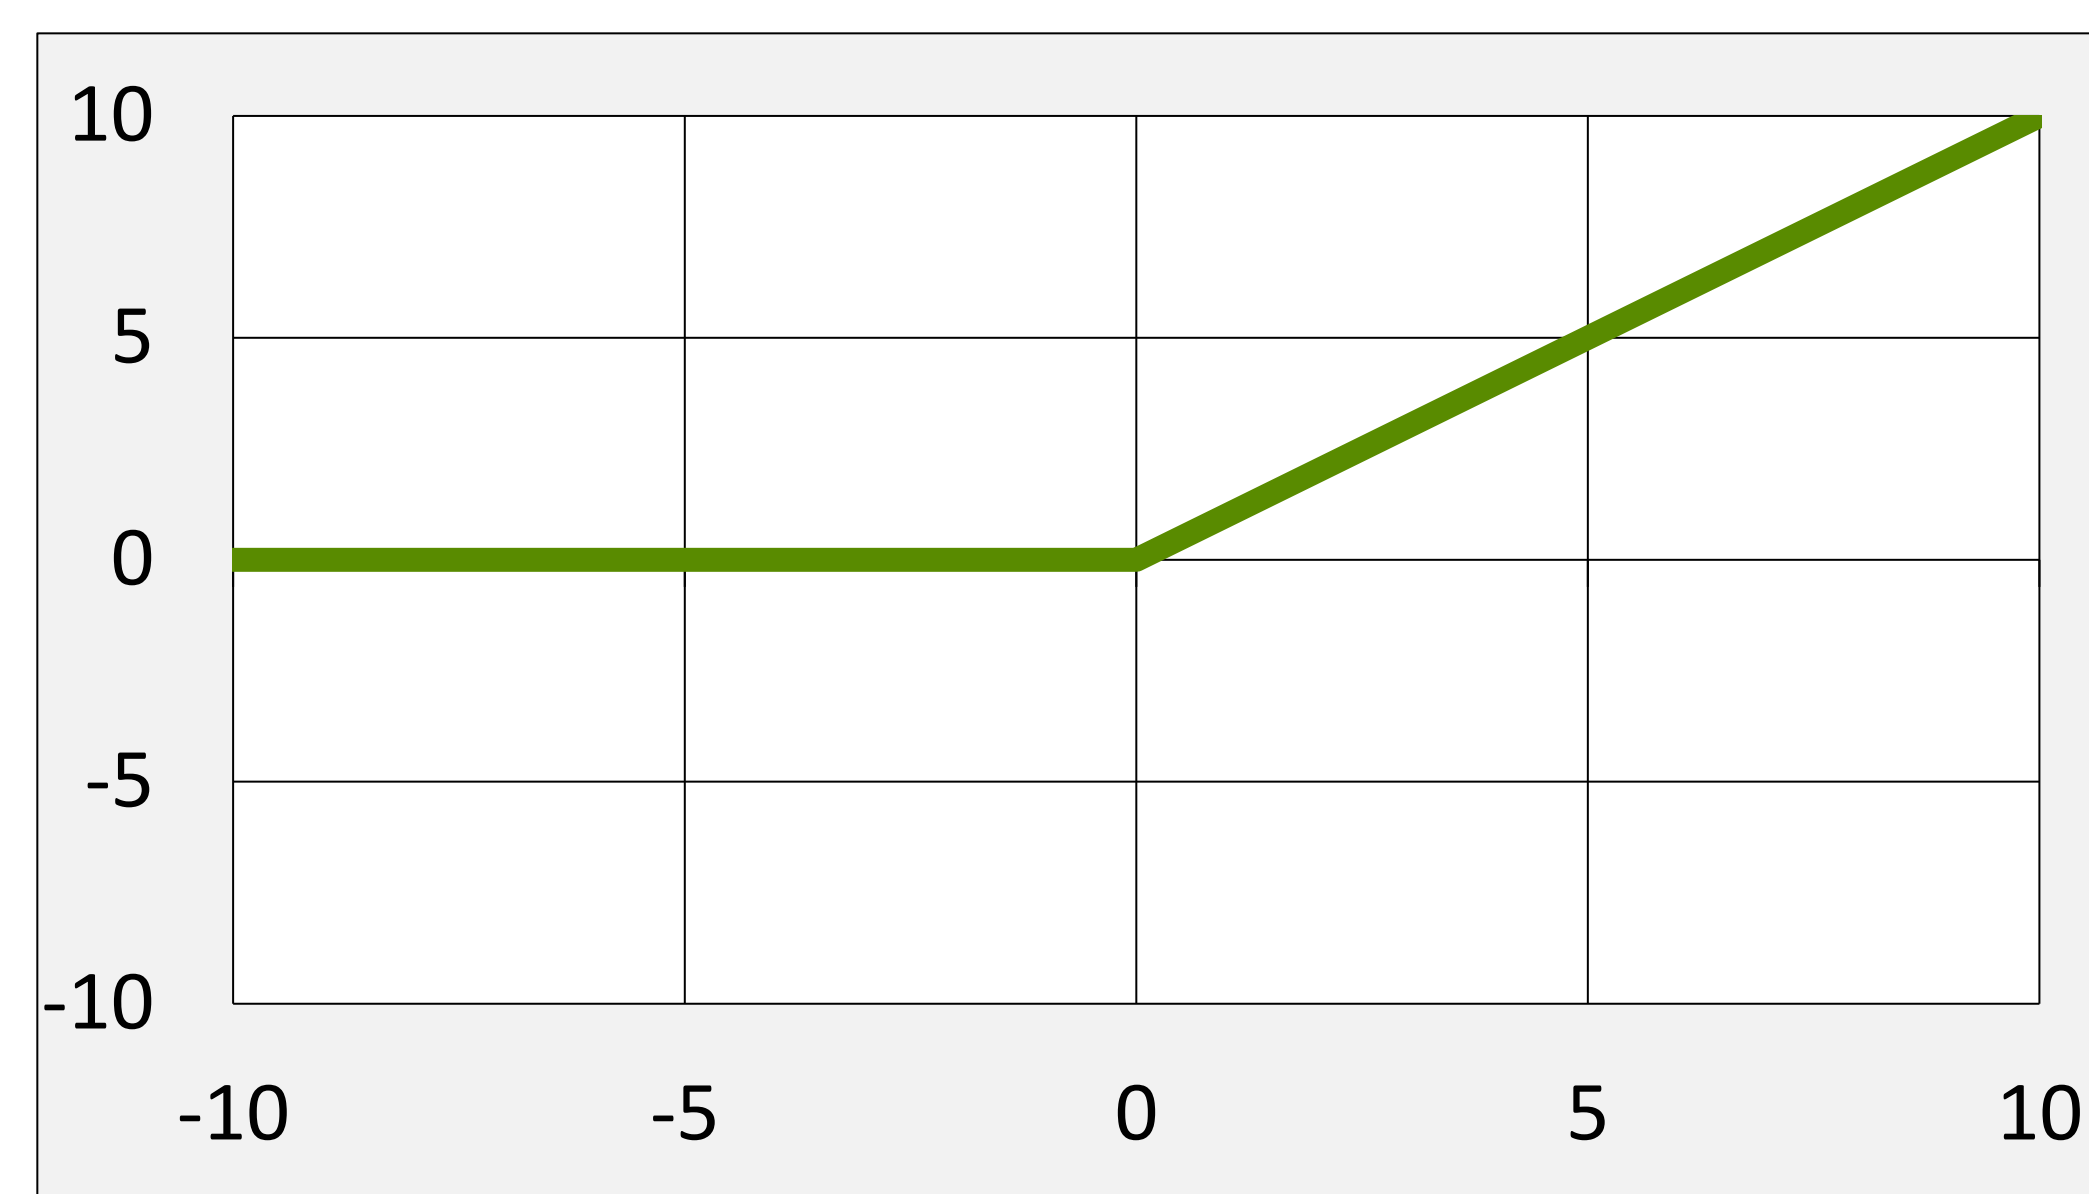
```
1 # Multiply each input
2 # with a weight (w) and
3 # add intercept (b)
4 y_hat = wx+b
```



ReLU

$$\hat{y} = \begin{cases} wx + b & \text{if } wx + b > 0 \\ 0 & \text{otherwise} \end{cases}$$


```
1 # Only return result
2 # if total is positive
3 linear = wx+b
4 y_hat = linear * (linear > 0)
```



Sigmoid


$$\hat{y} = \frac{1}{1 + e^{-(wx+b)}}$$

```
1 # Start with line
2 linear = wx + b
3 # Warp to - inf to 0
4 inf_to_zero = np.exp(-1 * linear)
5 # Squish to -1 to 1
6 y_hat = 1 / (1 + inf_to_zero)
```




活化函式(Activation Function)





Linear線性(Linear)




ReLUReLU



Sigmoid



活化函数(Activation Function)



過度擬合(overfitting)



過度擬合(overfitting)

為什麼不使用超大型神經網路？





過度擬合(overfitting)

哪個趨勢線更好？



過度擬合(overfitting)

哪個趨勢線更好？



訓練資料與驗證資料(Training vs Validation Data)

避免記憶化

訓練資料

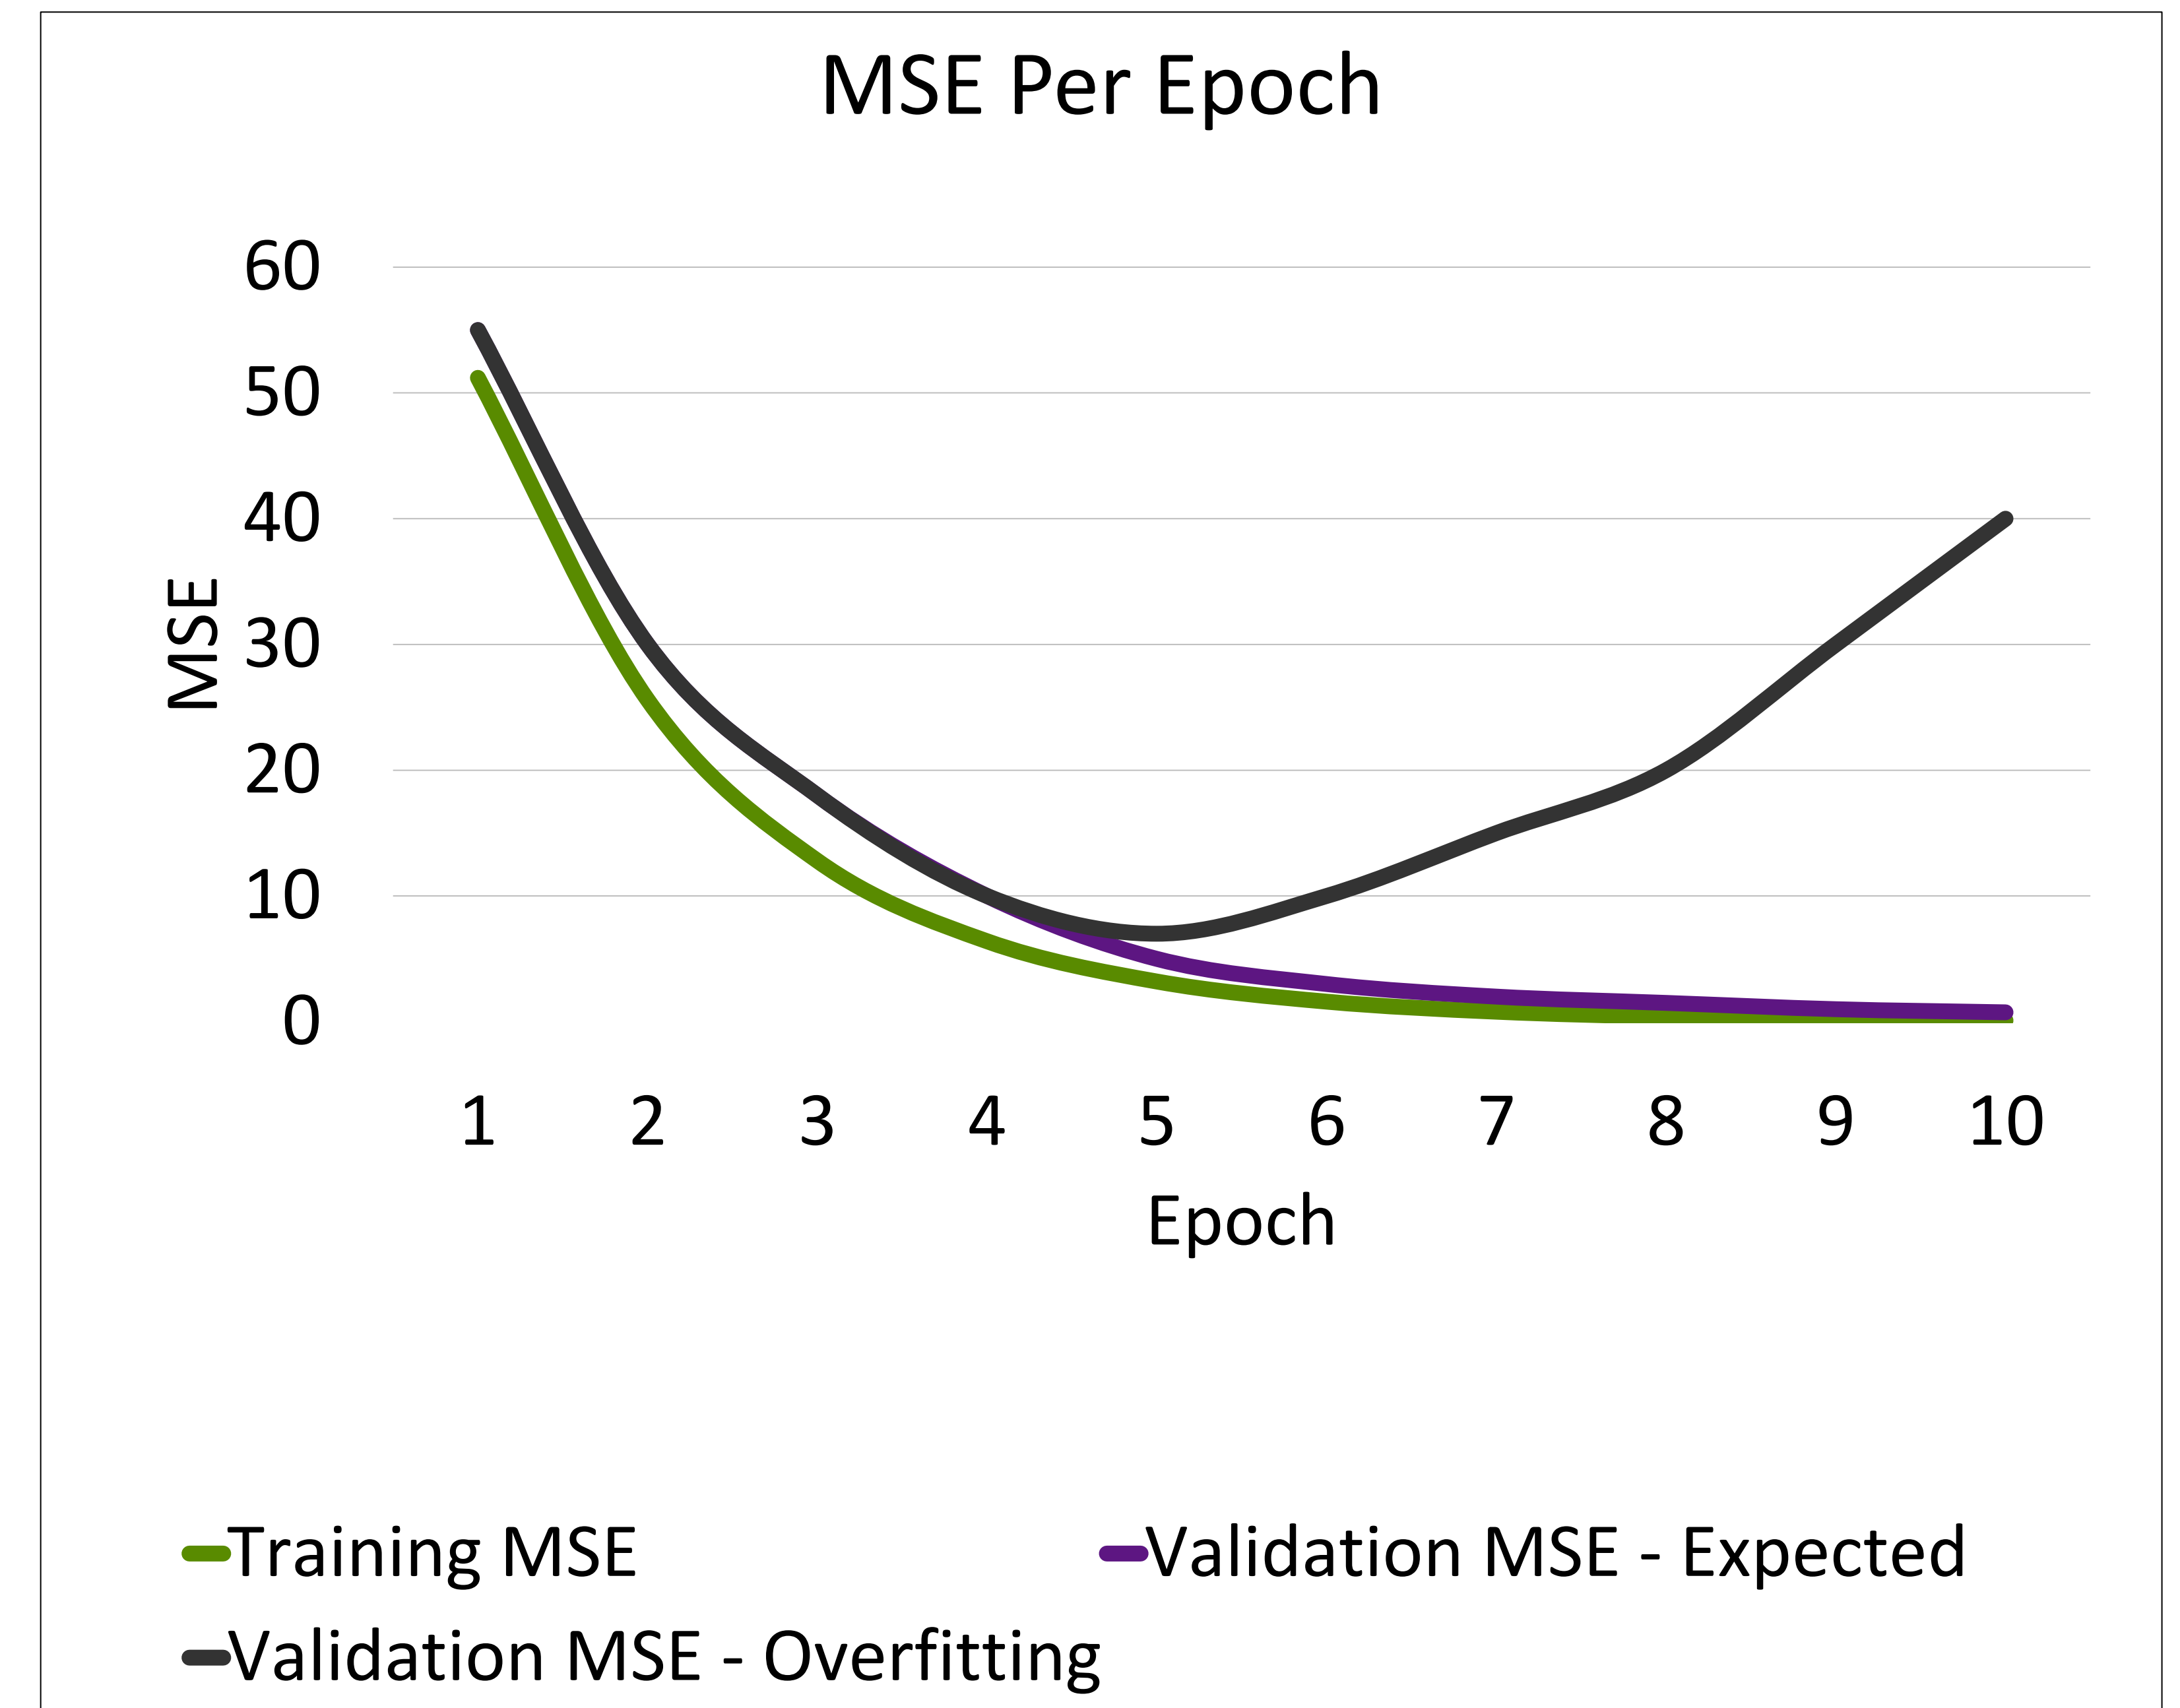
- 模型學習的核心資料集

驗證(Validation)資料

- 用於檢驗模型是否真正理解 (能夠泛化) 的新資料

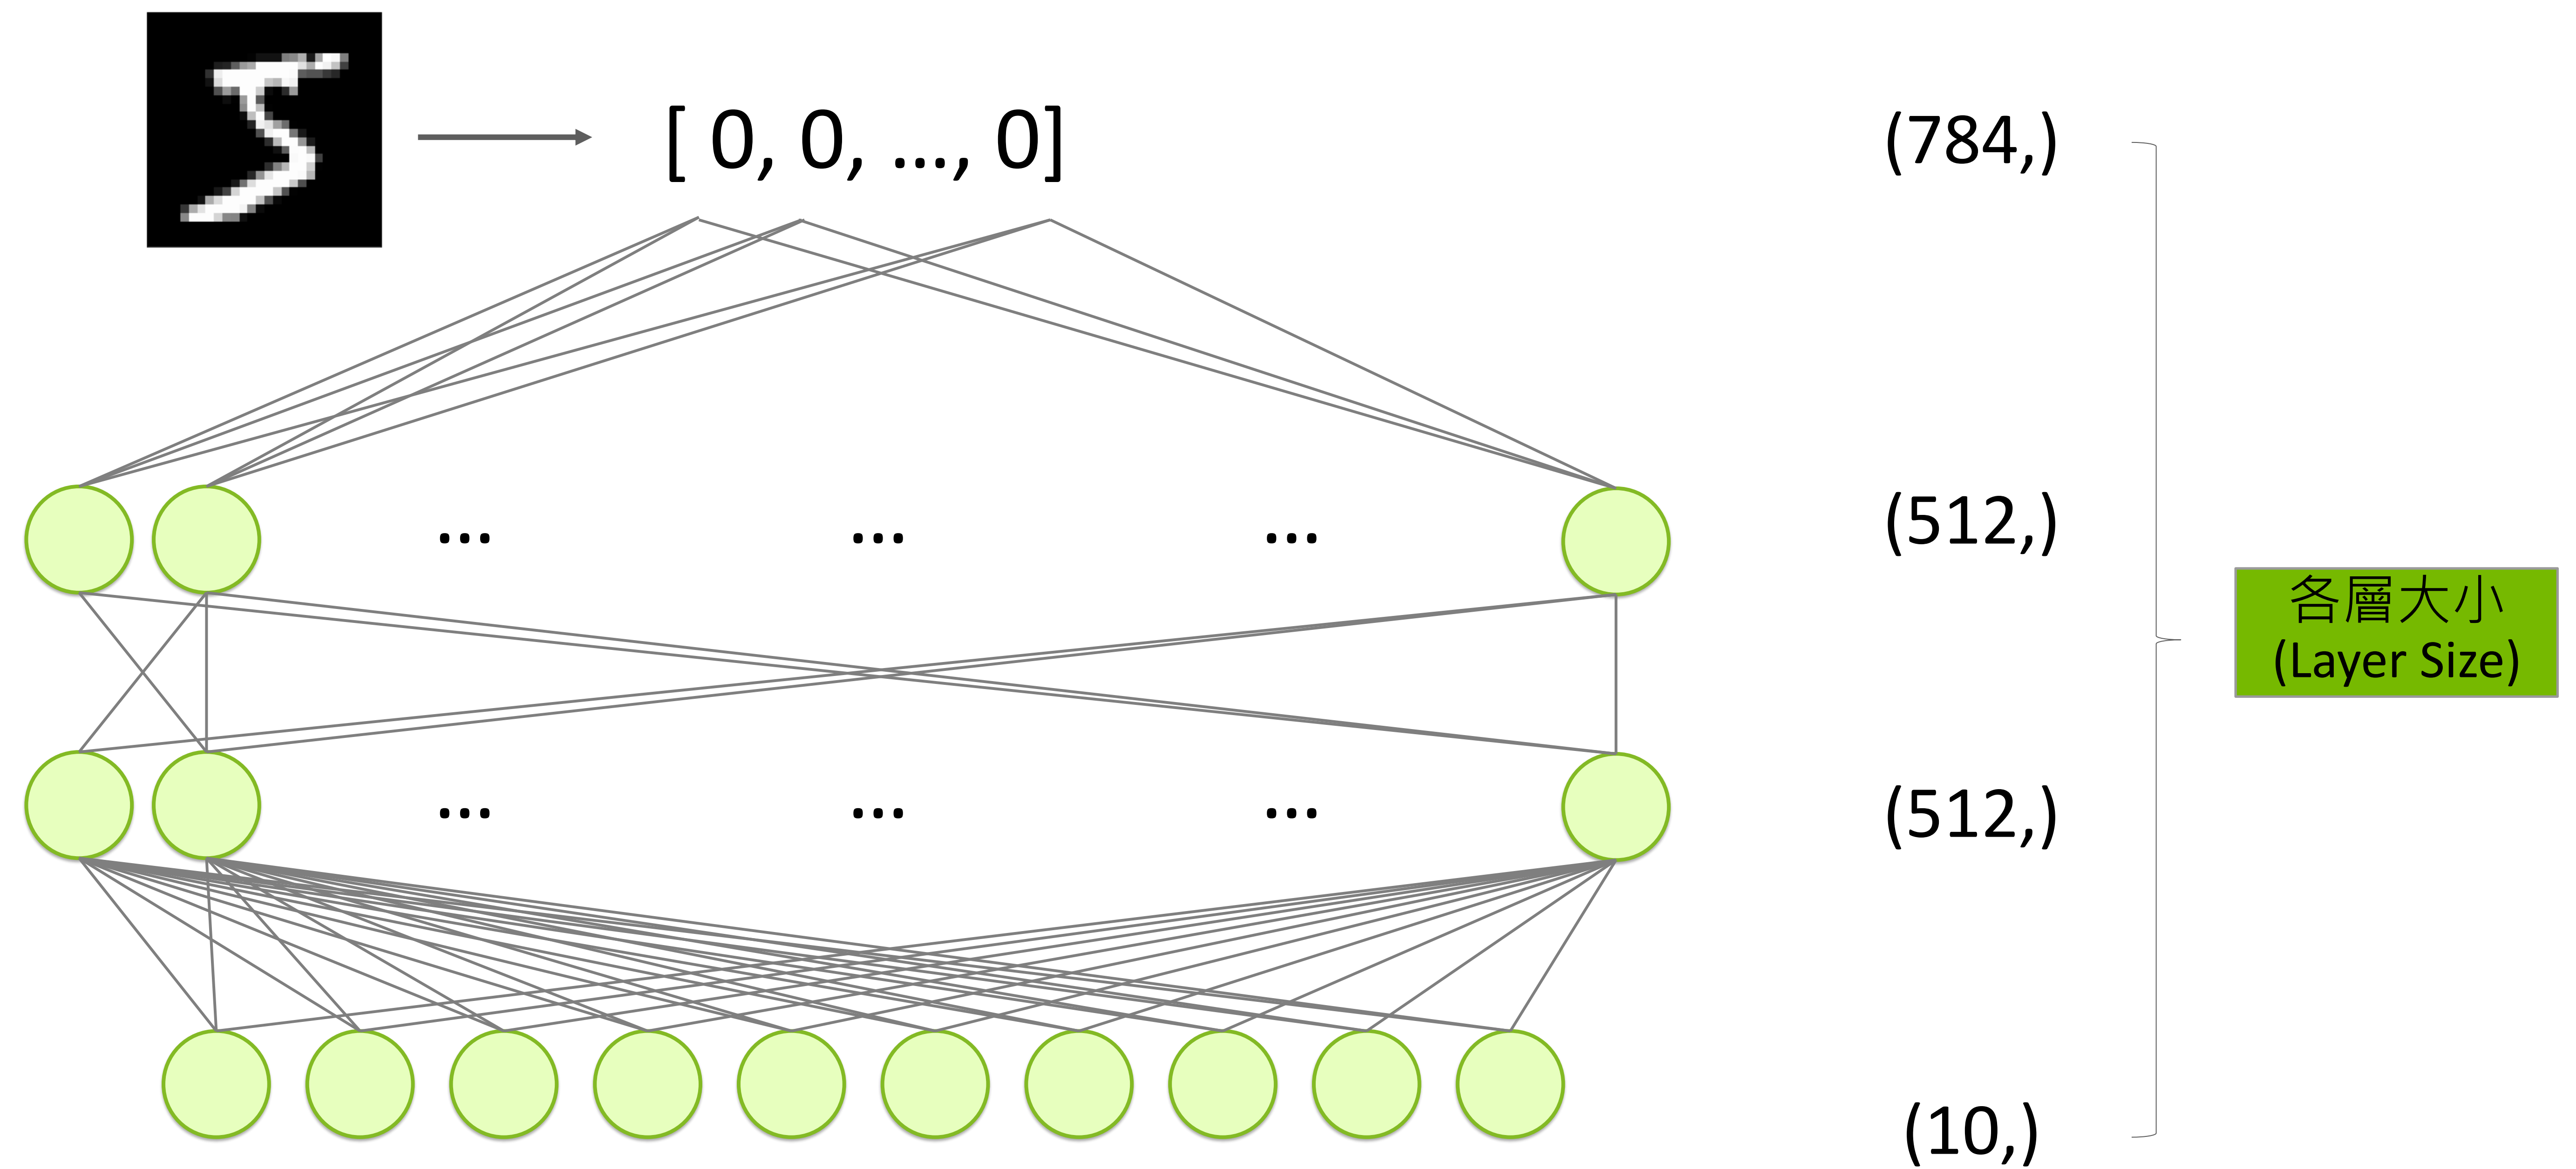
過度擬合(Overfitting)

- 當模型在訓練資料上表現良好，但在驗證(Validation)資料上表現不佳時 (顯示出記憶而非學習的跡象)
- 理想情況下，兩個資料集的準確度(accuracy)和損失函式(loss function)應該相似



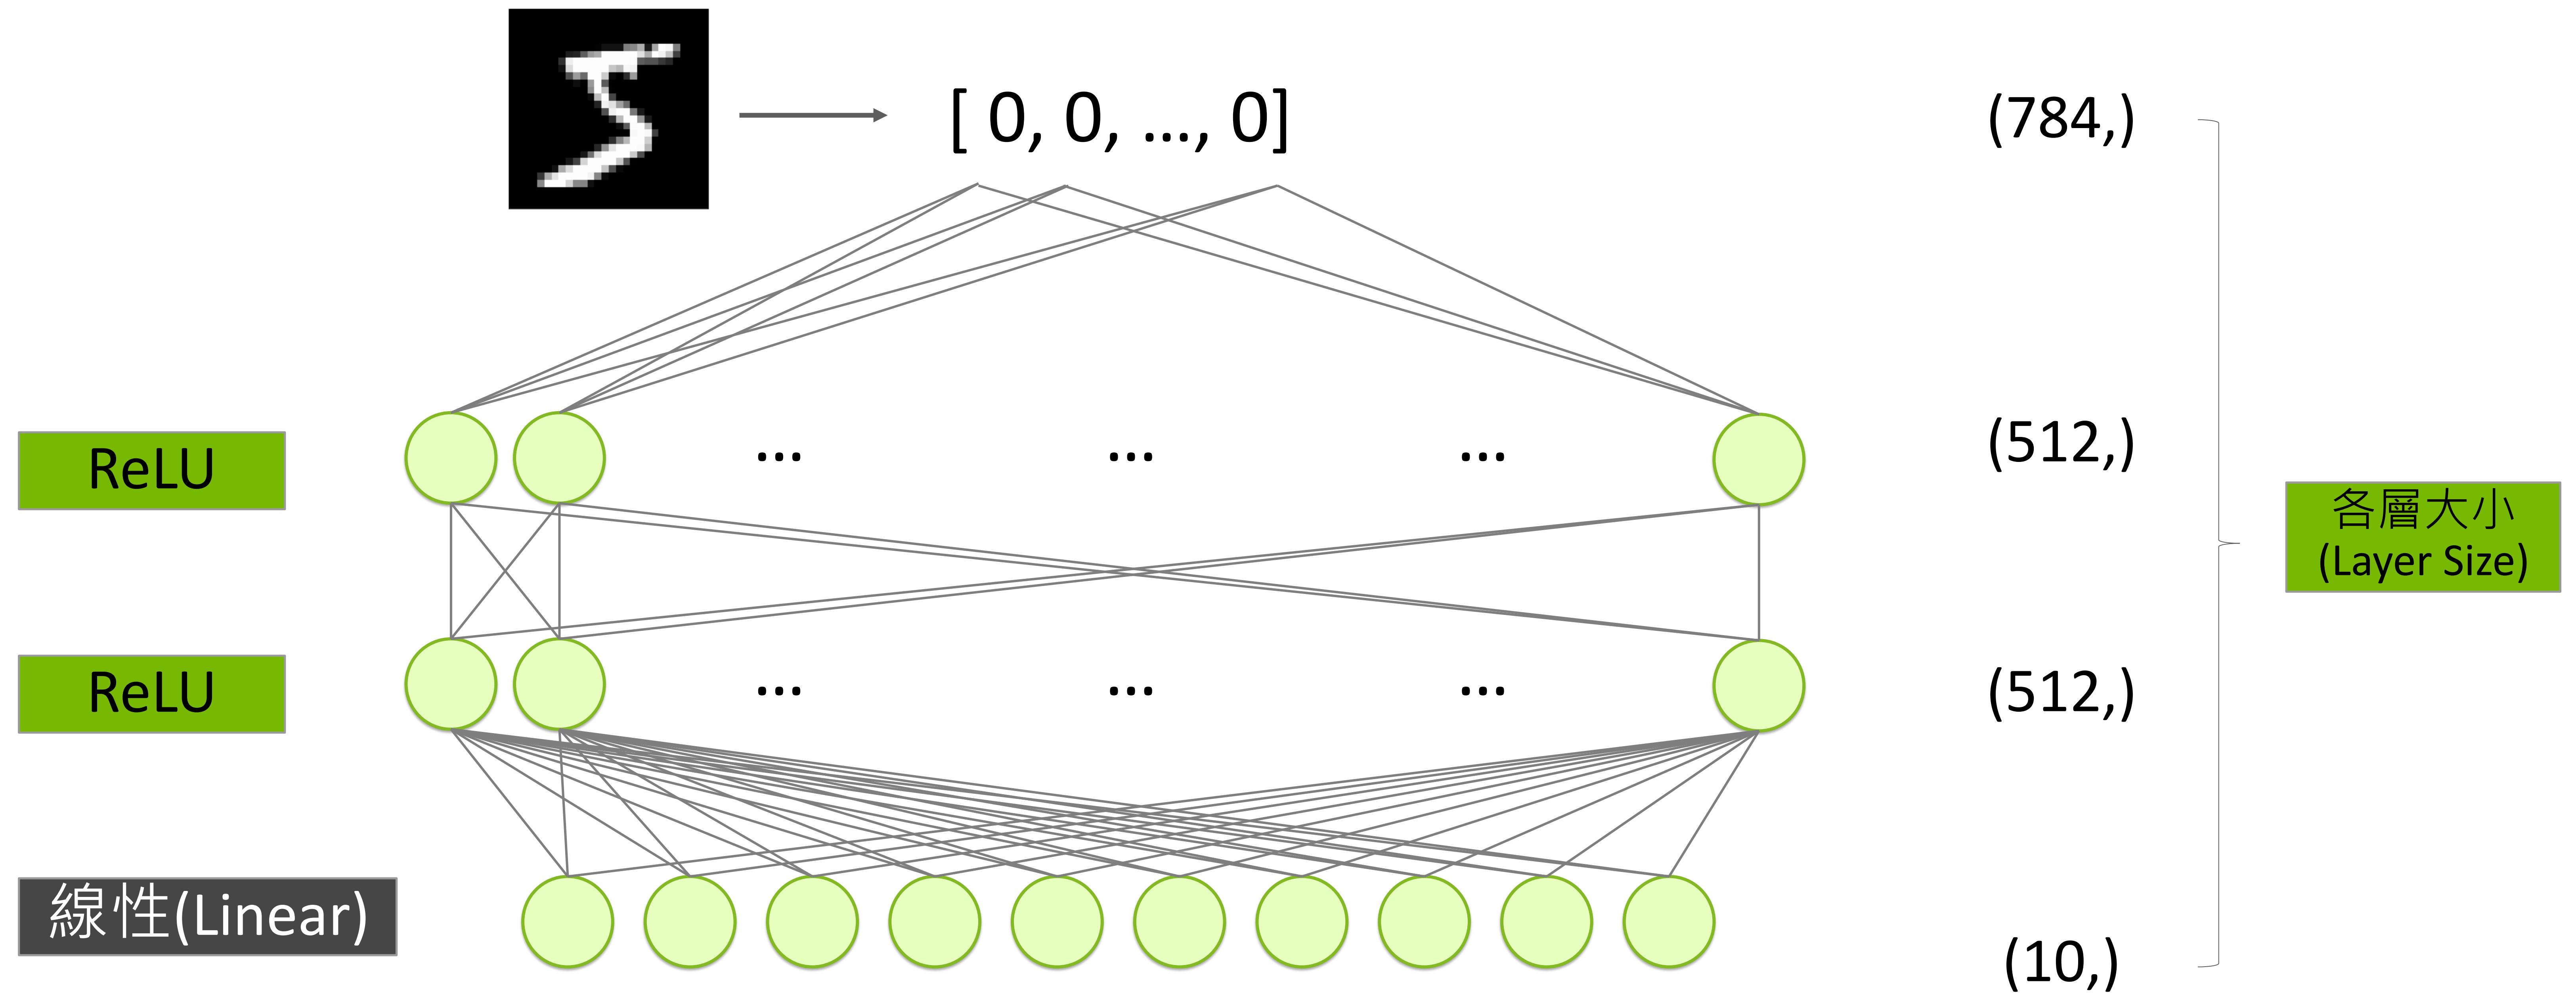
從迴歸到分類(From Regression to Classification)

MNIST模型



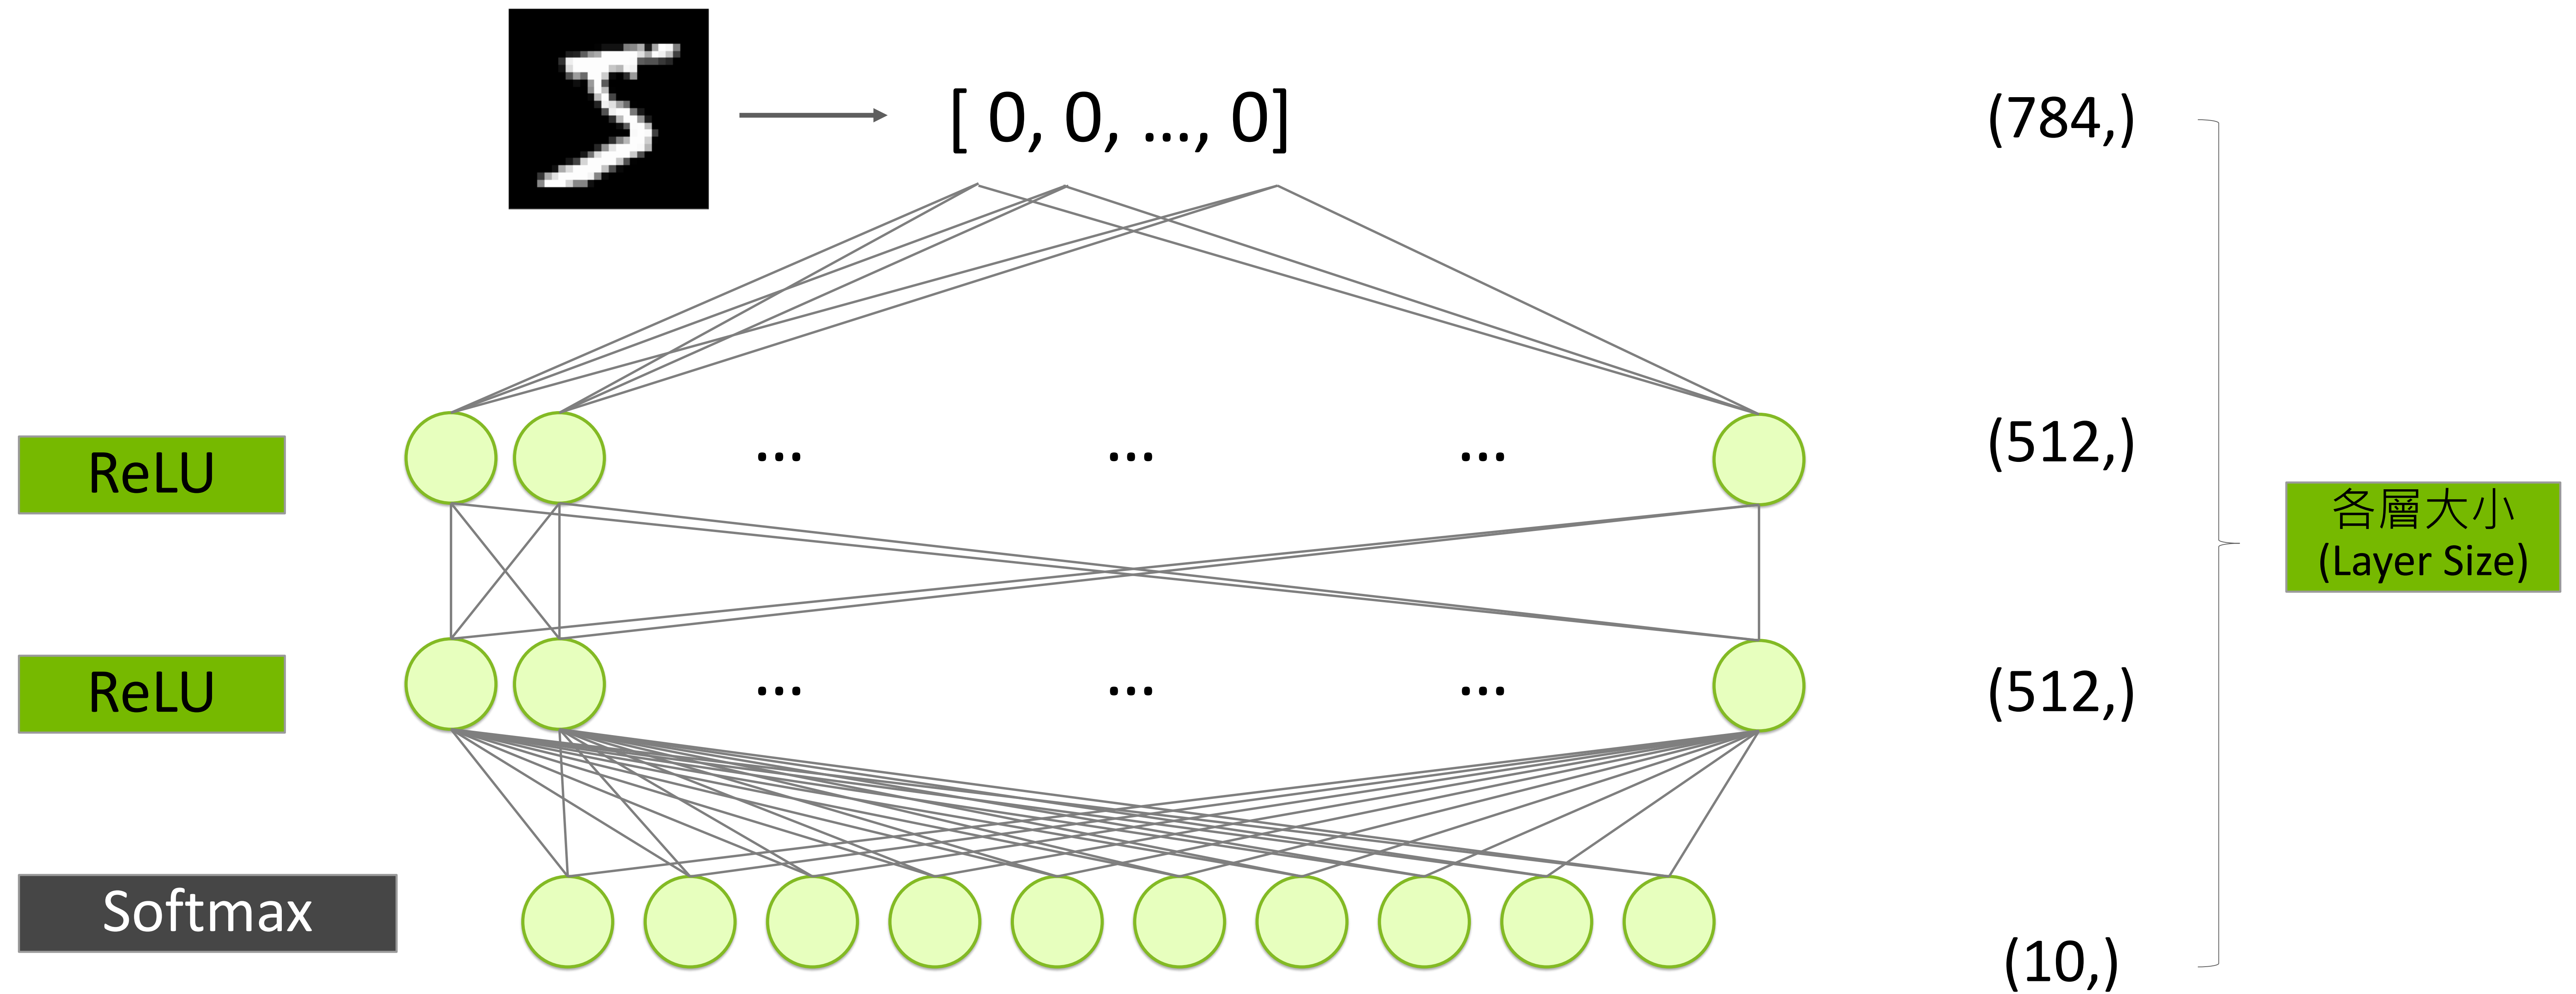
MNIST模型

預測過程




MNIST模型

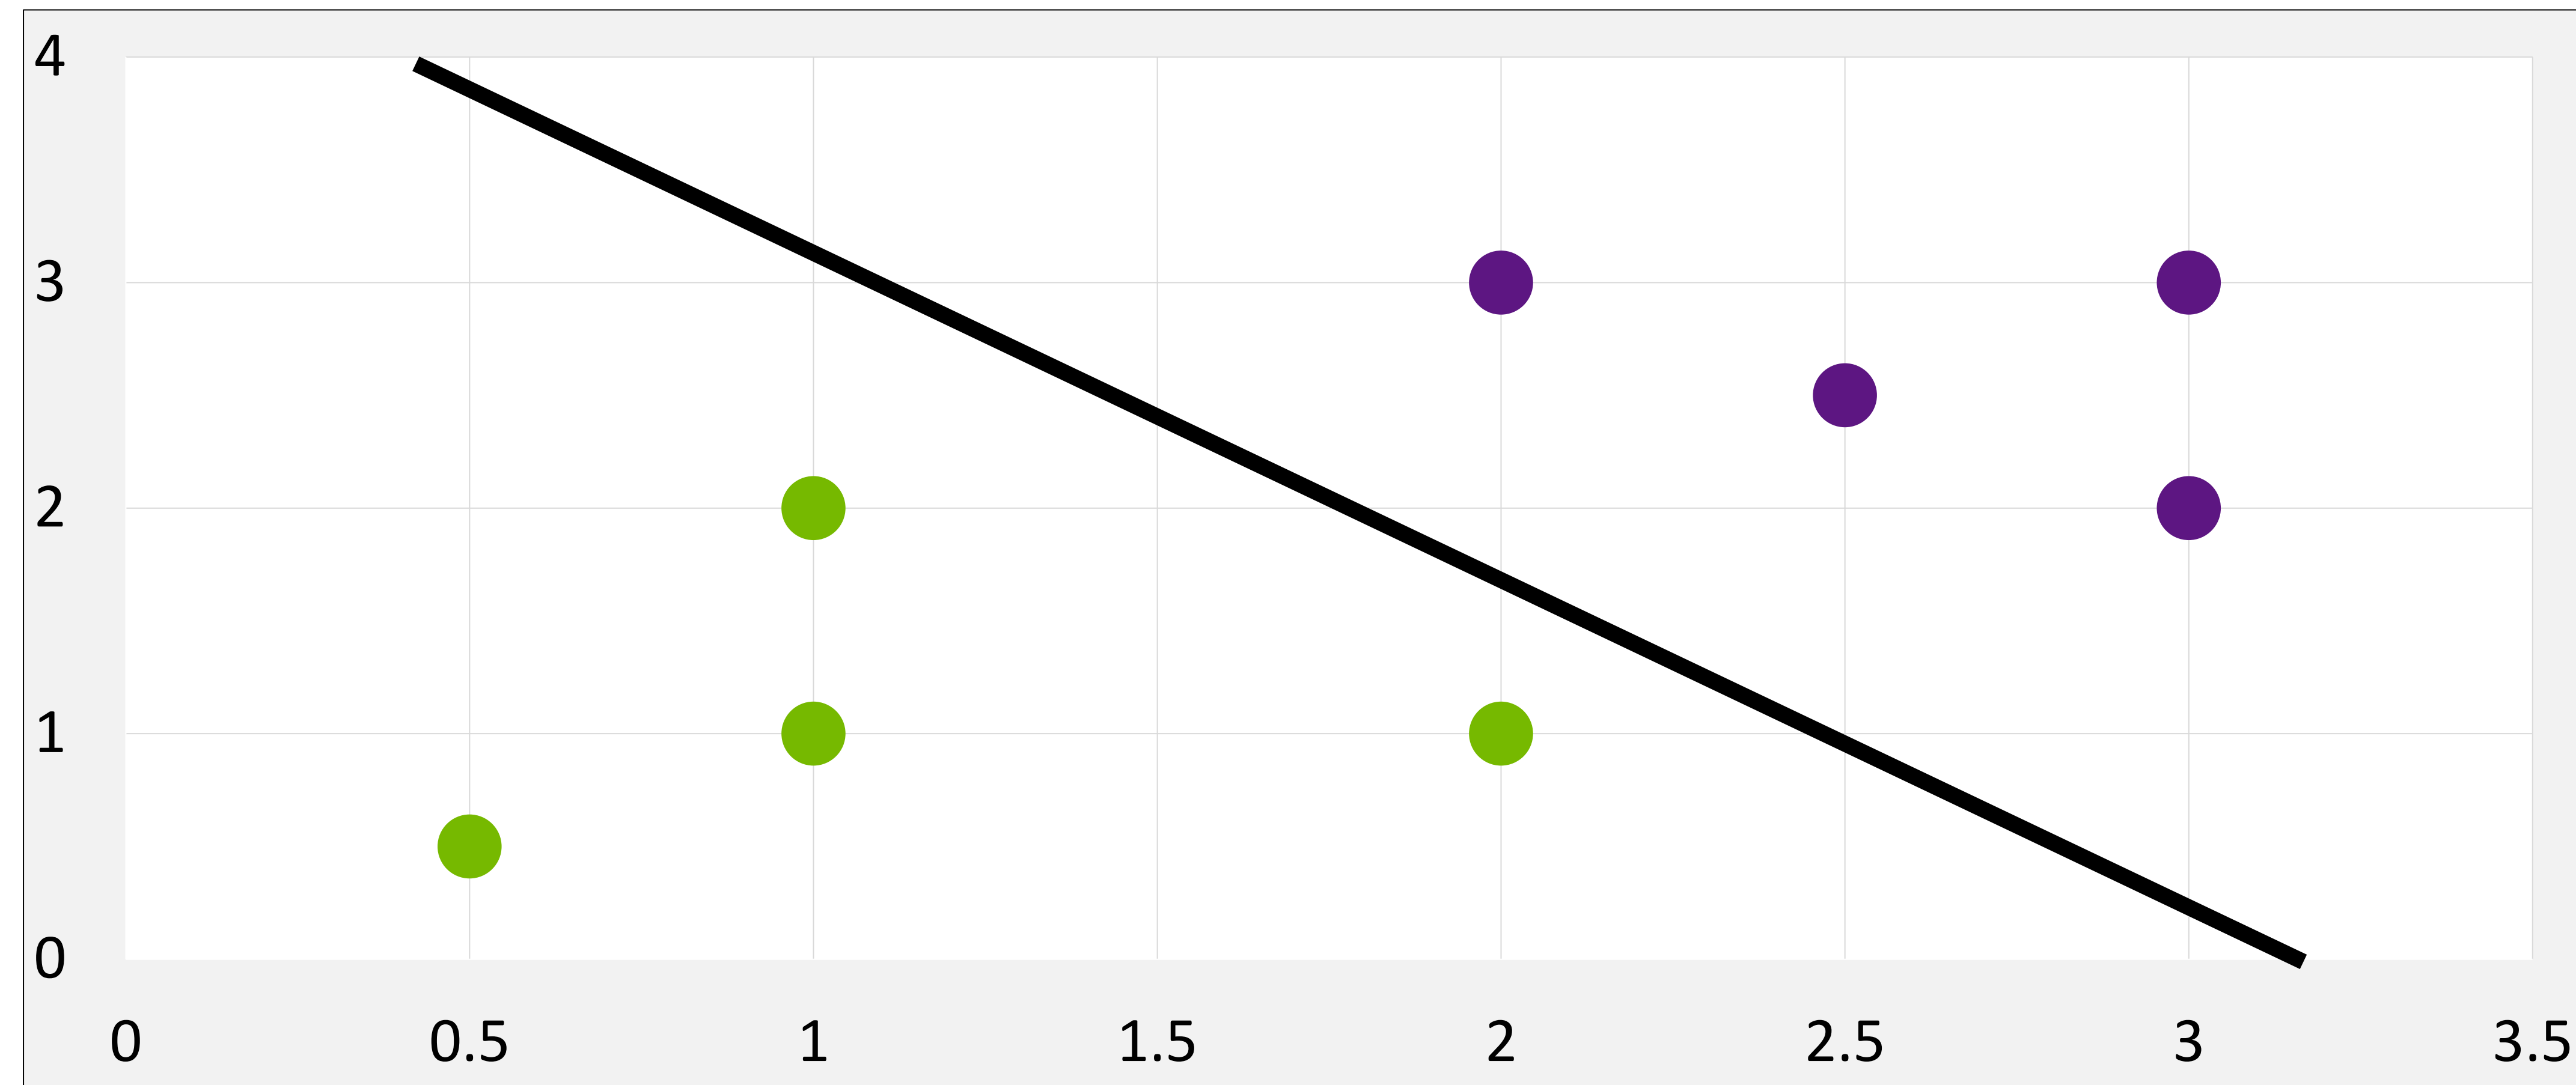
訓練過程





機率的RMSE ?




機率的RMSE ?



交叉熵(Cross Entropy)



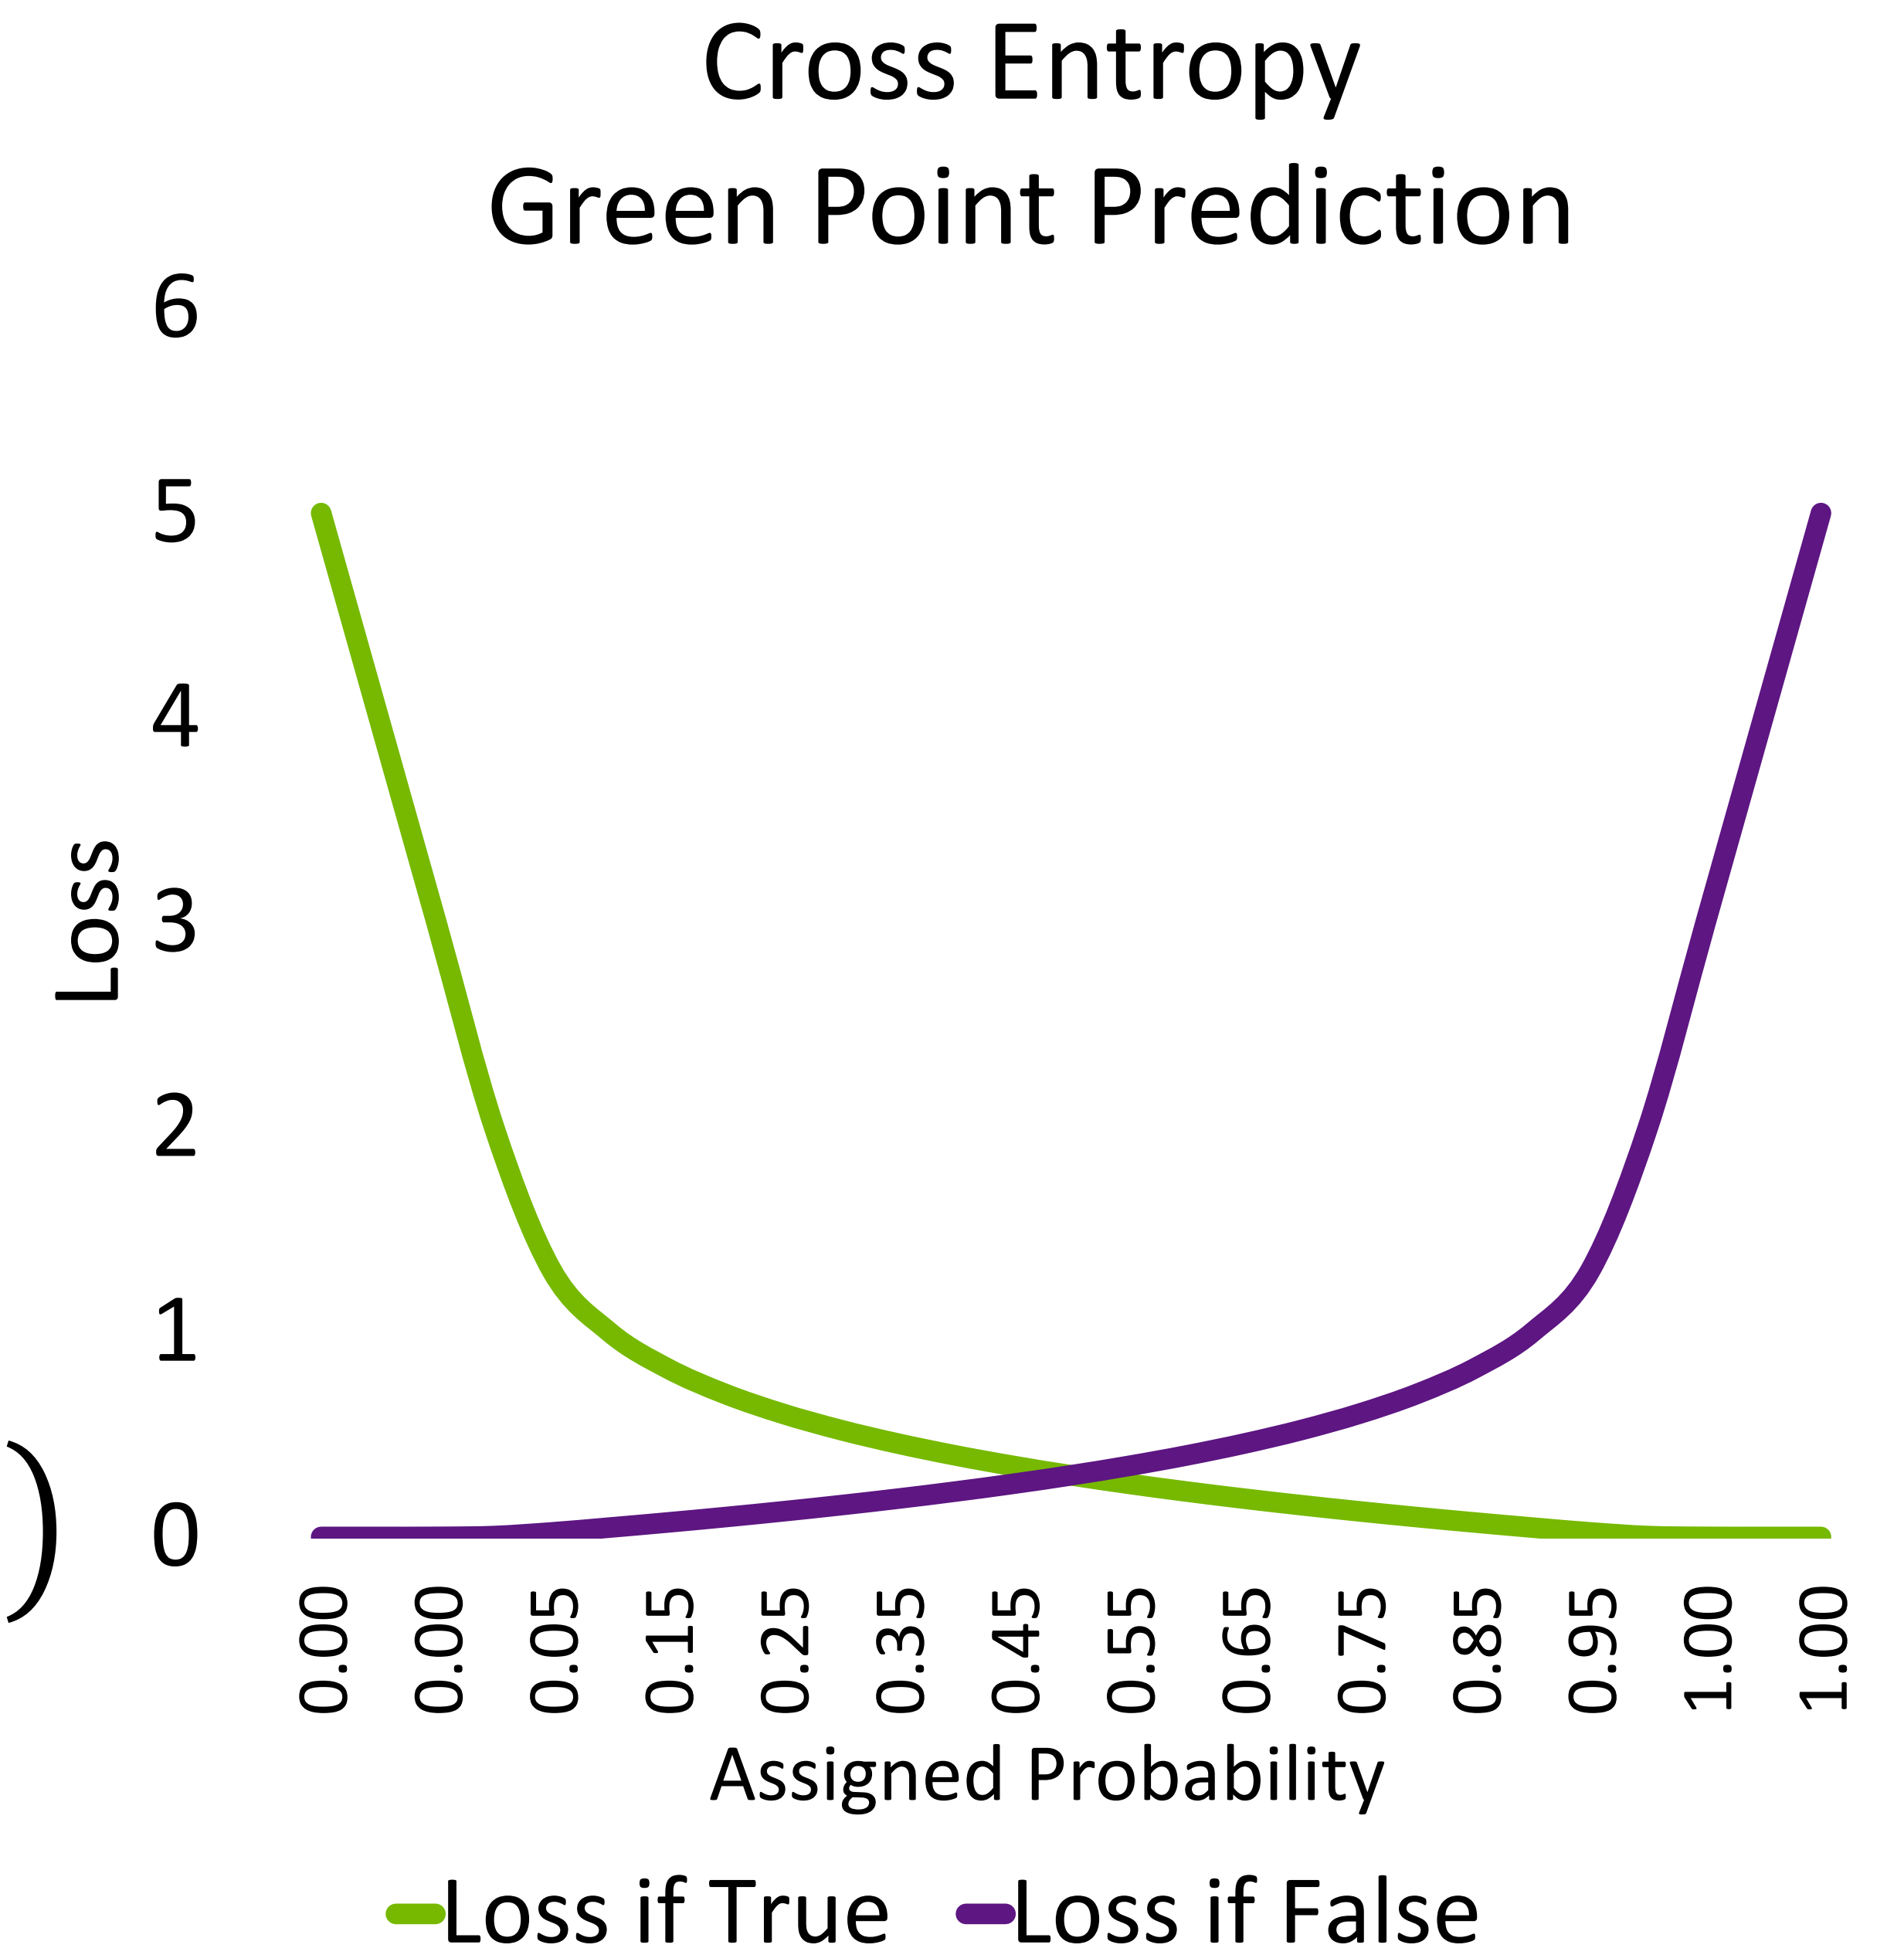
交叉熵(Cross Entropy)



$$Loss = -((t(x) \cdot \log(p(x)) + (1 - t(x)) \cdot \log(1 - p(x)))$$

$t(x)$ = target (0 if False, 1 if True)

$p(x)$ = probability prediction of point x



◆ 情況 1：真實值是正類 ($t(x) = 1$)

Green

$$\text{Loss} = -\log(p(x))$$


- 越接近 1 (正確)，loss 越小
- 越接近 0 (錯很離譜)，loss 越大 (趨近於無限大)

◆ 情況 2：真實值是負類 ($t(x) = 0$)


Purple

$$\text{Loss} = -\log(1 - p(x))$$


- 越接近 0 (正確)，loss 越小
- 越接近 1 (錯很離譜)，loss 越大 (趨近於無限大)



交叉熵(Cross Entropy)




```
1 def cross_entropy(y_hat, y_actual):  
2     """Infinite error for misplaced confidence."""  
3     loss = log(y_hat) if y_actual else log(1-y_hat)  
4     return -1*loss
```



彙總整理

下一個練習

美國手語字母(American Sign Language Alphabet)



Let's go!開始吧！



附錄：梯度下降(Gradient Descent)

幫助電腦作弊微積分

從錯誤中學習

$$MSE = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2 = \frac{1}{n} \sum_{i=1}^n (y - (mx + b))^2$$

$$MSE = \frac{1}{2} ((3 - (m(1) + b))^2 + (5 - (m(2) + b))^2)$$

$$\frac{\partial MSE}{\partial m} = 5m + 3b - 13$$


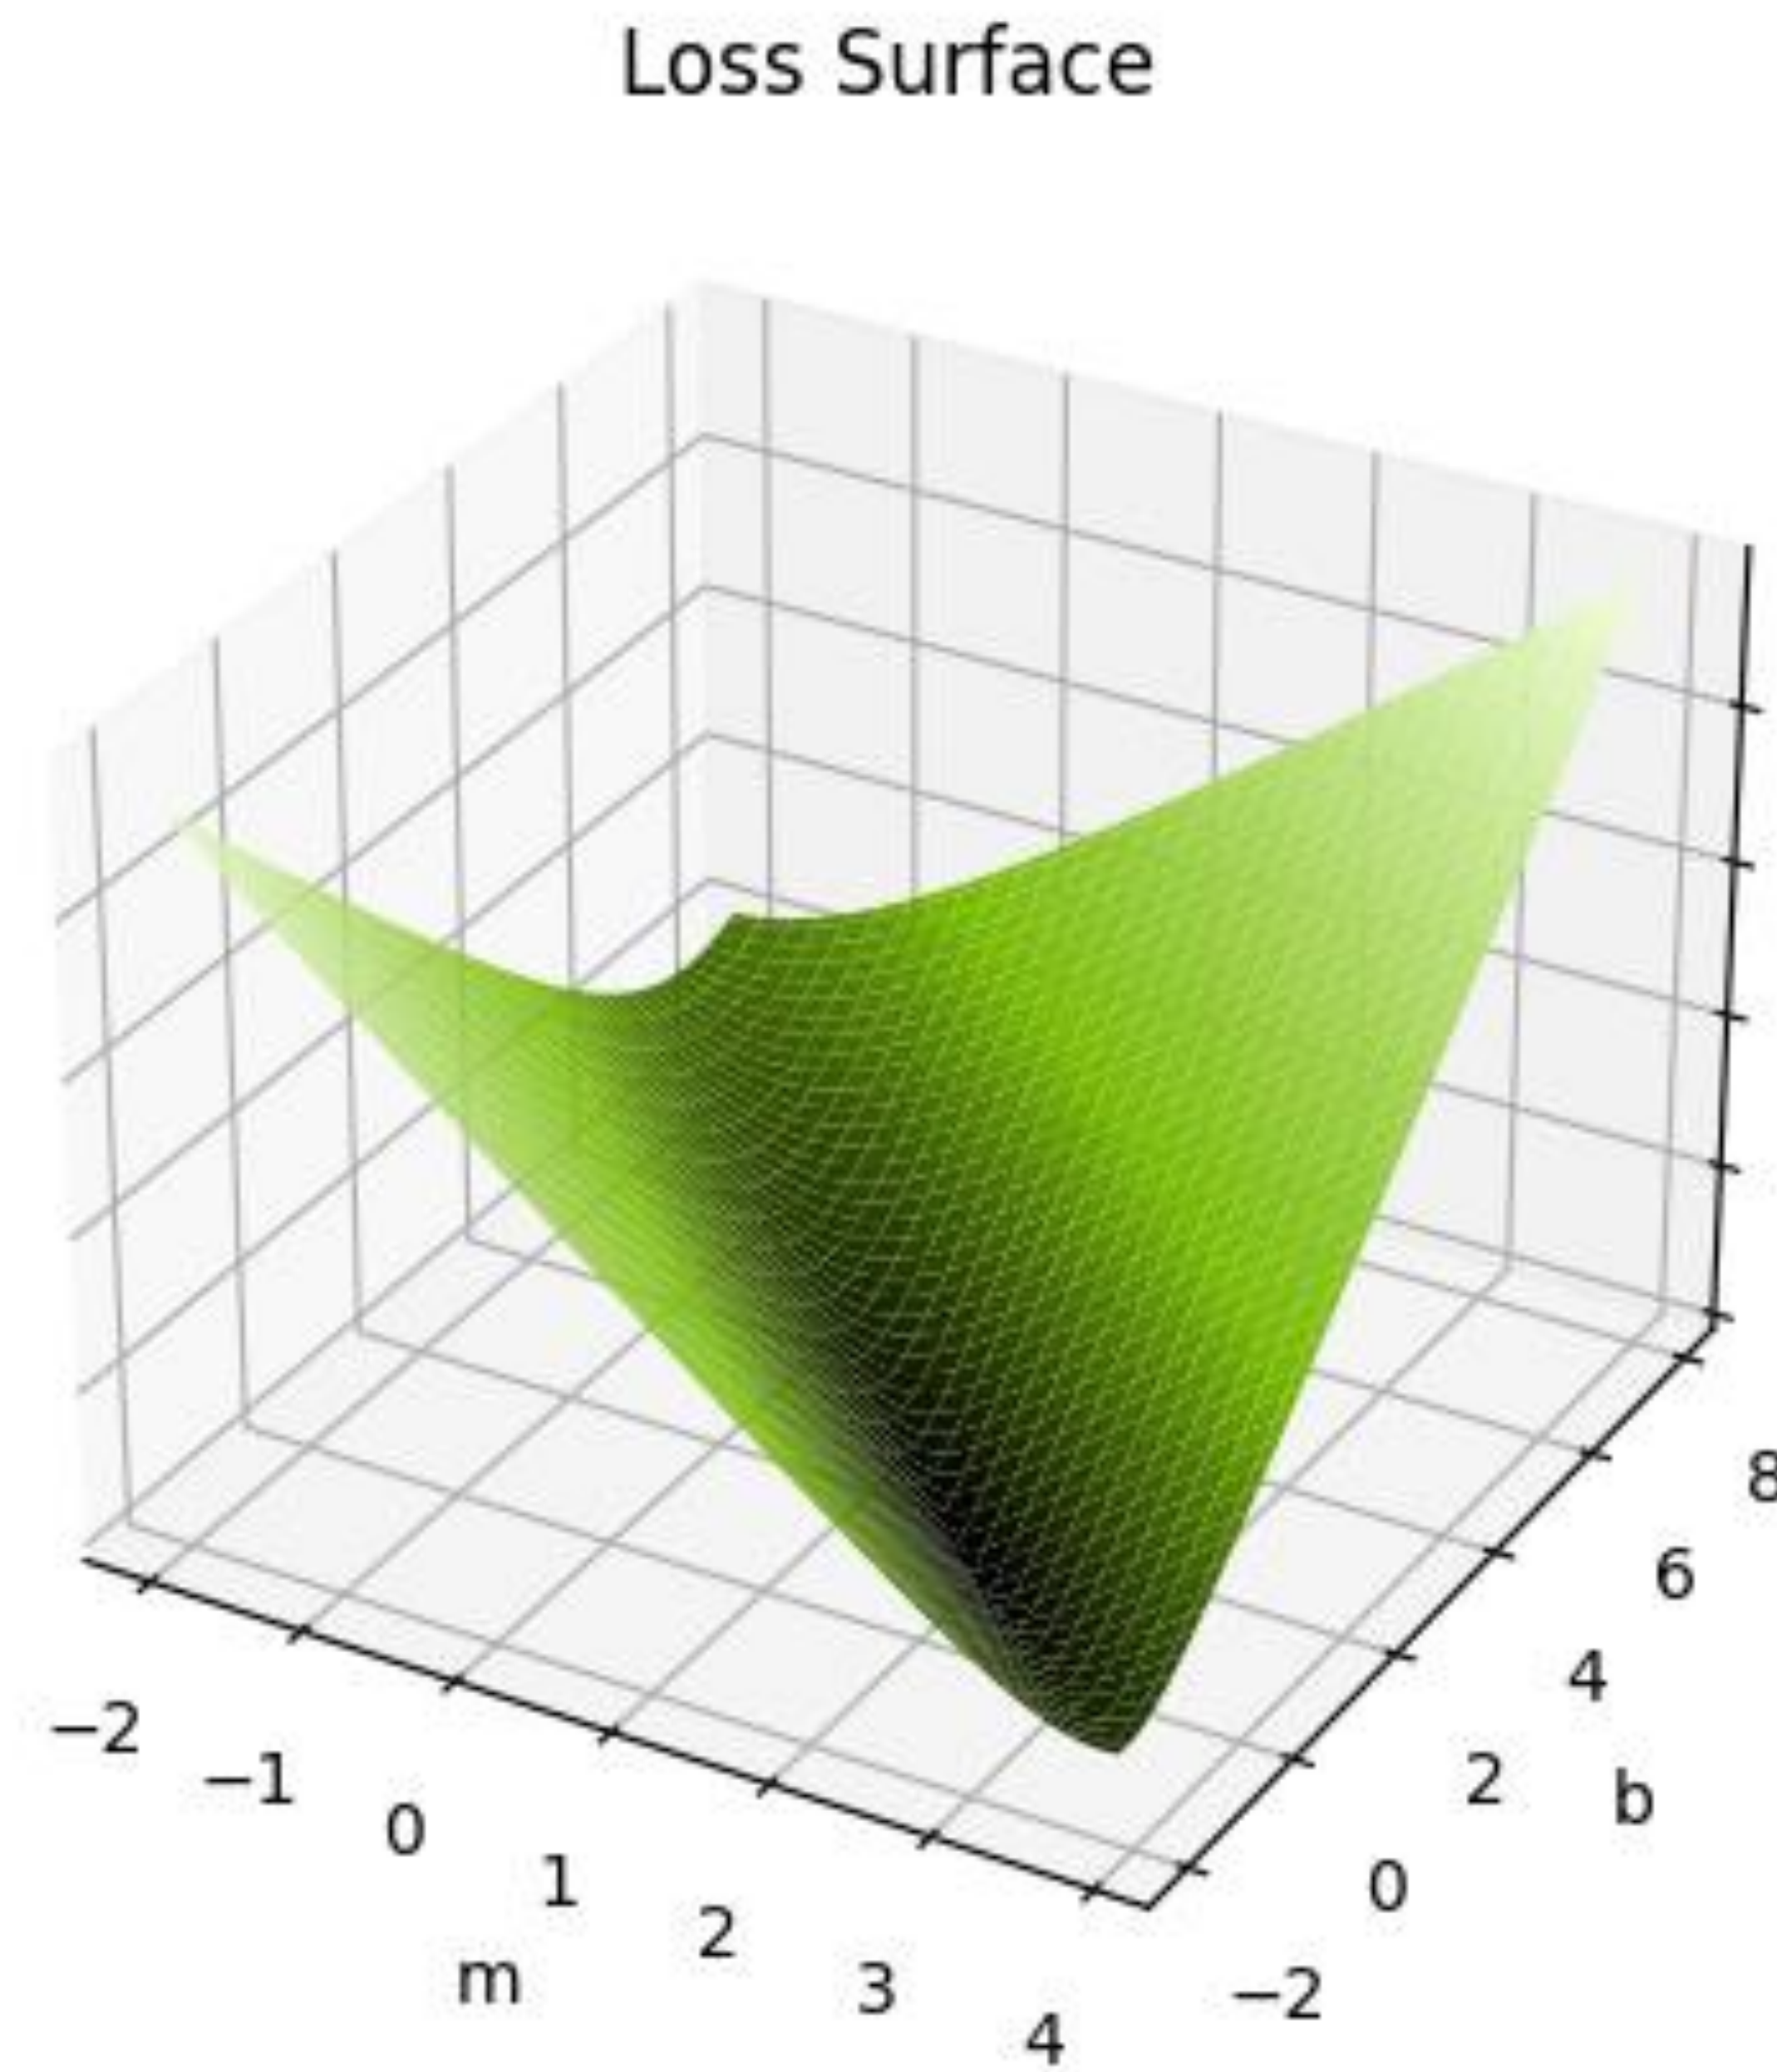
$$\frac{\partial MSE}{\partial b} = 3m + 2b - 8$$

$$\frac{\partial MSE}{\partial m} = -3$$

$$\frac{\partial MSE}{\partial b} = -1$$

$$m = -1$$
$$b = 5$$


損失曲線(Loss Curve)



損失曲線(Loss Curve)

$$\frac{\partial MSE}{\partial m} = -3$$

$$\frac{\partial MSE}{\partial b} = -1$$




損失曲線(Loss Curve)

$$\frac{\partial MSE}{\partial m} = -3 \quad \frac{\partial MSE}{\partial b} = -1$$

$$m := m - \lambda \frac{\partial MSE}{\partial m}$$

$$b := b - \lambda \frac{\partial MSE}{\partial b}$$




損失曲線(Loss Curve)

$$\frac{\partial MSE}{\partial m} = -3 \quad \frac{\partial MSE}{\partial b} = -1$$

$$m := m - \lambda \frac{\partial MSE}{\partial m}$$

$$\lambda = 2$$

$$b := b - \lambda \frac{\partial MSE}{\partial b}$$




損失曲線(Loss Curve)

$$\frac{\partial MSE}{\partial m} = -3 \quad \frac{\partial MSE}{\partial b} = -1$$

$$m := m - \lambda \frac{\partial MSE}{\partial m}$$

$$\lambda = .1$$

$$b := b - \lambda \frac{\partial MSE}{\partial b}$$



損失曲線(Loss Curve)

$$\lambda = .1$$

$$m := -1 + 3 \lambda = -0.7$$

$$b := 5 + \lambda = 5.1$$

